

**BỘ GIÁO DỤC VÀ ĐÀO TẠO
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ KỸ THUẬT
THÀNH PHỐ HỒ CHÍ MINH**

KHOA CÔNG NGHỆ THÔNG TIN



ĐỒ ÁN CUỐI KỲ

**ĐỀ TÀI: DỰ ĐOÁN NGUY CƠ MẮC BỆNH TIM DỰA TRÊN DỮ LIỆU
Y TẾ BẰNG CÁC MÔ HÌNH MACHINE LEARNING**

MÔN HỌC: LẬP TRÌNH R CHO PHÂN TÍCH

Mã học phần: RPAN233577_01

Giảng viên hướng dẫn: TS.Phan Thị Thể

Sinh viên thực hiện :

Dương Thị Kim Ngân - 24133040

Nguyễn Minh Thư – 24133061

Nguyễn Thị Kiều Trang – 24133064

Nguyễn Thị Ngọc Trâm - 24133066

Thành phố Hồ Chí Minh, tháng 6 năm 2026

Nhận xét của giảng viên

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

TP. HCM, ngày 24 tháng 06 năm 2026

Giảng viên ký tên

MỤC LỤC

LỜI CẢM ƠN	1
TÓM TẮT	2
CHƯƠNG 1. GIỚI THIỆU.....	3
1.1. Đặt vấn đề	3
1.2. Mục tiêu nghiên cứu.....	3
1.3. Phạm vi nghiên cứu.....	4
1.4. Cấu trúc báo cáo.....	4
CHƯƠNG 2. CƠ SỞ LÝ THUYẾT	6
2.1. Tổng quan về bệnh tim	6
2.1.1. Khái niệm.....	6
2.1.2. Các yếu tố nguy cơ mắc bệnh tim.....	6
2.2. Tổng quan về bài toán phân loại nhị phân	6
2.2.1. Khái niệm về bài toán phân loại nhị phân	6
2.2.2. Chiến lược chuyển đổi bài toán phân loại đa nhãn.....	6
2.2.3. Các thách thức chính của bài toán phân loại nhị phân	7
2.3. Tổng quan về tiền xử lý dữ liệu.....	8
2.3.1. Khái niệm tiền xử lý dữ liệu	8
2.3.2. Mục đích của tiền xử lý dữ liệu	8
2.3.3. Các kỹ thuật tiền xử lý dữ liệu.....	9
2.4. Tổng quan về Machine Learning.....	11
2.4.1. Khái niệm.....	11
2.4.2. Vai trò	11
2.4.3. Các lĩnh vực ứng dụng.....	12
2.5. Các thuật toán sử dụng.....	15
2.5.1. Support Vector Machine (SVM)	15
2.5.2. K - Nearest Neighbors (KNN).....	16
2.5.3. Logistic Regression	18
2.6. Các chỉ số đánh giá mô hình	19

CHƯƠNG 3. DỮ LIỆU (DATA)	20
3.1. Giới thiệu bộ dữ liệu	20
3.2. Mô tả các thuộc tính	20
3.3. Phân tích Khám phá dữ liệu (EDA)	21
3.3.1. Tổng quan về bộ dữ liệu	21
3.3.2. Thống kê mô tả	22
3.3.3. Kiểm tra chất lượng dữ liệu	24
3.3.4. Phân phối biến số	25
3.3.5. Quan hệ với các biến	26
3.4. Tiền xử lý dữ liệu	29
3.4.1. Xử lý dữ liệu thiếu	29
3.4.2. Xử lý dữ liệu trùng lặp	30
3.4.3. Xử lý ngoại lệ	31
3.4.4. Mã hóa biến phân loại	32
3.4.5. Chuẩn hóa dữ liệu	34
CHƯƠNG 4. TRỰC QUAN HÓA DỮ LIỆU (DATA VISUALIZATION)	36
4.1. Phân bố dữ liệu	36
4.1.1. Phân bố biến mục tiêu	36
4.1.2. Phân bố các biến định lượng	37
4.1.3. Phân bố các biến định tính	42
4.2. Phân tích tương quan giữa các biến	50
4.3. So sánh đặc điểm giữa nhóm mắc bệnh và không mắc bệnh	53
CHƯƠNG 5. XÂY DỰNG MÔ HÌNH HÓA DỮ LIỆU (DATA MODELING)	56
5.1. Giới thiệu mô hình	56
5.2. Chia tập dữ liệu	57
5.3. Thiết lập Cross-Validation	57
5.4. Xây dựng mô hình 1: Logistic Regression	58
5.4.1 Mục tiêu và phương pháp	58
5.4.2. Triển khai	58

5.5. Xây dựng mô hình 2: K - Nearest Neighbors (KNN)	59
5.5.1. Mục tiêu và Phương pháp	59
5.5.2. Triển khai	60
5.6. Xây dựng mô hình 3: Support Vector Machine (SVM)	62
5.6.1. Mục tiêu và phương pháp	62
5.6.2. Triển khai	63
CHƯƠNG 6. THỰC NGHIỆM, KẾT QUẢ VÀ THẢO LUẬN	65
6.1. Kết quả Mô hình 1: Logistic Regression	65
6.1.1. Đánh giá mô hình	65
6.1.2. Kết quả đánh giá	65
6.1.3. Kết luận	66
6.2. Kết quả Mô hình 2: K - Nearest Neighbors (KNN)	67
6.2.1. Đánh giá mô hình	67
6.2.2. Đánh giá kết quả	67
6.2.3. Đánh giá biểu đồ trực quan	68
6.2.4. Kết luận	69
6.3. Kết quả Mô hình 3: Support Vector Machine (SVM)	69
6.3.1. Đánh giá mô hình	69
6.3.2. Kết quả	70
6.3.3. Biểu đồ trực quan	71
6.4. So sánh các mô hình	72
6.5. Biểu đồ ROC-AUC	73
6.6. Kiểm tra Overfitting	75
6.7. Ma trận nhầm lẫn (Confusion Matrix)	76
6.7.1. Logistic Regression	76
6.7.2. K – Nearest Neighbors (KNN)	77
6.7.3. Support Vector Machine (SVM)	78
6.7.4. Kết luận	78
6.8. Đánh giá mức độ ảnh hưởng của các biến lâm sàng	79

6.8.1. Đánh giá các biến.....	79
6.8.2. Nhận định về các yếu tố.....	81
6.9. Dự đoán bệnh nhân mắc bệnh tim	81
6.9.1. Thông tin bệnh nhân	81
6.9.2. Quá trình triển khai	82
6.9.3. Kết quả dự đoán.....	83
CHƯƠNG 7. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN	84
7.1. Kết luận	84
7.2. Hạn chế của nghiên cứu.....	84
7.3. Hướng phát triển trong tương lai	85
BẢNG PHÂN CÔNG VÀ ĐÁNH GIÁ	86
TÀI LIỆU THAM KHẢO.....	88

LỜI CẢM ƠN

Nhóm em xin gửi lời cảm ơn chân thành và sâu sắc nhất đến cô Phan Thị Thê - giảng viên bộ môn Lập trình R, người đã trực tiếp giảng dạy và hướng dẫn nhóm em trong suốt học kỳ vừa qua.

Nhờ sự tận tình của cô, nhóm em đã được trang bị những kiến thức nền tảng vững chắc về ngôn ngữ R, từ các thao tác xử lý, làm sạch dữ liệu, đến các kỹ thuật trực quan hóa và đặc biệt là ứng dụng các thuật toán Machine Learning trong phân tích dự báo. Những bài giảng chi tiết, ví dụ thực tế cùng các buổi hướng dẫn, giải đáp thắc mắc của cô đã giúp nhóm em tự tin hơn khi triển khai đề tài đồ án cuối kỳ: "Dự đoán nguy cơ mắc bệnh tim dựa vào dữ liệu y tế bằng Machine Learning".

Trong quá trình thực hiện đồ án, cô đã dành thời gian đọc và góp ý cho từng phần của nhóm, từ việc lựa chọn mô hình, đánh giá độ chính xác đến cách trình bày báo cáo sao cho logic và thuyết phục. Những lời nhận xét, góp ý đó thực sự quý giá, giúp nhóm em nhận ra những thiếu sót để kịp thời điều chỉnh và hoàn thiện đồ án tốt hơn.

Mặc dù nhóm em đã cố gắng hết sức, đồ án khó tránh khỏi những hạn chế nhất định do thời gian và kinh nghiệm thực tế còn ít. Nhóm em rất mong tiếp tục nhận được sự chỉ bảo và những ý kiến đóng góp từ cô để nhóm em có thể rút kinh nghiệm cho các đồ án tiếp theo cũng như trong công việc sau này.

Nhóm em xin trân trọng cảm ơn!

TÓM TẮT

Bệnh tim mạch là một trong những nguyên nhân hàng đầu gây tử vong trên toàn cầu. Việc phát hiện sớm nguy cơ mắc bệnh tim đóng vai trò quan trọng trong điều trị và giảm tỷ lệ tử vong. Đồ án này được thực hiện nhằm xây dựng mô hình Machine Learning để dự đoán nguy cơ mắc bệnh tim dựa trên các chỉ số y tế như tuổi, huyết áp, nồng độ cholesterol, nhịp tim, đường huyết lúc đói...

Nhóm sử dụng ngôn ngữ lập trình R với các thư viện chính như dblyr, ggplot2, tidyr, caret, ranger, pROC,... Dữ liệu được sử dụng là bộ dữ liệu về bệnh tim Heart Disease Cleveland Dataset bao gồm 305 mẫu và 14 thuộc tính. Quy trình thực hiện bao gồm xử lý giá trị thiếu, loại bỏ dữ liệu trùng lặp và ngoại lai, chuyển đổi các biến phân loại về đúng ý nghĩa y tế, sau đó chuẩn hóa dữ liệu để đảm bảo tính đồng nhất. Tiếp theo, ba thuật toán học máy gồm Hồi quy Logistic, SVM và KNN được huấn luyện và đánh giá qua các chỉ số Accuracy, Sensitivity, Precision, F1-score. Với mô hình có hiệu suất tốt nhất, nhóm tiến hành trực quan hóa so sánh giữa dự đoán và thực tế, xác định các yếu tố ảnh hưởng quan trọng nhất đến bệnh tim, từ đó đưa ra kết luận về những chỉ số cần ưu tiên theo dõi trong phòng ngừa và chẩn đoán sớm.

Kết quả thực nghiệm cho thấy mô hình Logistic Regression chính xác cao nhất (khoảng 83.15% theo chỉ số Accuracy), cùng với các chỉ số đánh giá khác như ROC và AUC. Đồ án chứng minh rằng Machine Learning, đặc biệt khi triển khai trên R, là một công cụ hiệu quả, có thể hỗ trợ các bác sĩ trong việc đưa ra quyết định chẩn đoán và sàng lọc bệnh tim sớm.

CHƯƠNG 1. GIỚI THIỆU

1.1. Đặt vấn đề

Bệnh tim mạch từ lâu đã được xem là một trong những mối đe dọa lớn nhất đối với sức khỏe con người trên toàn cầu. Theo Tổ chức Y tế Thế giới, mỗi năm có khoảng 17,9 triệu ca tử vong do bệnh tim mạch, chiếm gần 32% tổng số ca tử vong trên toàn thế giới. Điều đáng nói là phần lớn trong số đó có thể phòng tránh được nếu phát hiện sớm và can thiệp kịp thời. Việc nhận diện nguy cơ từ sớm không chỉ giúp bác sĩ đưa ra phác đồ điều trị hiệu quả mà còn tạo cơ hội cho bệnh nhân thay đổi lối sống, giảm đáng kể gánh nặng chi phí điều trị cũng như tỷ lệ tử vong. Tuy nhiên, trong thực tế lâm sàng, việc đánh giá nguy cơ bệnh tim thường phụ thuộc nhiều vào kinh nghiệm cá nhân của bác sĩ và các xét nghiệm đơn lẻ, dễ dẫn đến bỏ sót hoặc chậm trễ do tính phức tạp và tương tác giữa nhiều yếu tố cùng lúc.

Chính từ thách thức này, Machine Learning nổi lên như một giải pháp đầy triển vọng trong lĩnh vực y tế. Khác với cách tiếp cận thống kê truyền thống, các thuật toán học máy có khả năng tự động phát hiện những mô hình, quy luật tiềm ẩn từ khối lượng lớn dữ liệu lịch sử, từ đó hỗ trợ dự đoán chính xác hơn. Ứng dụng Machine Learning vào bài toán dự đoán nguy cơ bệnh tim cho phép tận dụng tối đa các chỉ số lâm sàng như tuổi, huyết áp, cholesterol, nhịp tim, tiền sử hút thuốc hay tiểu đường... để đưa ra cảnh báo sớm một cách khách quan và nhất quán. Đặc biệt, với sự hỗ trợ của ngôn ngữ R việc xây dựng và triển khai các mô hình dự báo trở nên khả thi hơn bao giờ hết.

Xuất phát từ những lý do trên, đề án này được thực hiện nhằm xây dựng mô hình dự đoán nguy cơ mắc bệnh tim dựa trên dữ liệu y tế, hướng đến mục tiêu tạo ra một công cụ hỗ trợ hữu ích cho các bác sĩ trong công tác sàng lọc và chẩn đoán sớm.

1.2. Mục tiêu nghiên cứu

Mục tiêu trọng tâm đầu tiên là xây dựng và huấn luyện các mô hình phân loại có khả năng nhận diện bệnh nhân có nguy cơ hay không có nguy cơ mắc bệnh tim, từ đó tạo ra một công cụ hỗ trợ ra quyết định cho các bác sĩ trong quá trình sàng lọc lâm sàng. Bên cạnh đó, một mục tiêu quan trọng không kém là so sánh hiệu suất giữa các thuật toán học máy khác nhau. Việc so sánh này không chỉ giúp xác định mô hình phù hợp nhất cho bộ dữ liệu

bệnh tim mà còn cung cấp cái nhìn thực tế về ưu, nhược điểm của từng thuật toán trong bối cảnh dữ liệu y tế vốn có tính không cân bằng và phức tạp. Cuối cùng, từ mô hình có hiệu suất cao nhất, đề án sẽ xác định các yếu tố ảnh hưởng quan trọng nhất đến nguy cơ bệnh tim, góp phần định hướng cho các biện pháp phòng ngừa và theo dõi sức khỏe chủ động.

1.3. Phạm vi nghiên cứu

Đề án này tập trung xây dựng và đánh giá các mô hình Machine Learning để dự đoán nguy cơ mắc bệnh tim, được giới hạn trong các phạm vi cụ thể sau.

Về dữ liệu, nhóm sử dụng bộ dữ liệu về bệnh tim Heart Disease Cleveland Dataset. Đây là bộ dữ liệu về bệnh tim, bao gồm 305 mẫu với 14 thuộc tính liên quan đến các chỉ số lâm sàng như tuổi, giới tính, nồng độ cholesterol trong máu, nhịp tim,...

Về công cụ và thuật toán, đề án chỉ sử dụng ngôn ngữ lập trình R cùng các thư viện chuyên dụng. Ba thuật toán được lựa chọn để thử nghiệm bao gồm Hồi quy Logistic, SVM và KNN.

Về đánh giá, hiệu suất của các mô hình được đo lường dựa trên các chỉ số cơ bản gồm Accuracy, Sensitivity, Precision, F1-score. Đề án không đi sâu vào các khía cạnh như triển khai mô hình vào thực tế hay tích hợp với hệ thống y tế. Kết quả dự đoán chỉ mang tính chất tham khảo, hỗ trợ bác sĩ trong chẩn đoán sớm chứ không thay thế hoàn toàn các phương pháp lâm sàng chính thống.

1.4. Cấu trúc báo cáo

Báo cáo đề án được tổ chức thành 7 chương, trình bày tuần tự từ cơ sở lý thuyết đến thực nghiệm và kết luận.

Chương 1: Giới thiệu trình bày bối cảnh và tính cấp thiết của đề tài, tầm quan trọng của việc phát hiện sớm bệnh tim, vai trò của Machine Learning trong y tế, cùng với mục tiêu, phạm vi nghiên cứu và cấu trúc báo cáo.

Chương 2: Cơ sở lý thuyết hệ thống các khái niệm nền tảng về bệnh tim, các yếu tố nguy cơ, tổng quan về Machine Learning, giới thiệu ba thuật toán được sử dụng (Hồi quy Logistic, SVM, KNN) và các chỉ số đánh giá mô hình.

Chương 3: Dữ liệu Dataset giới thiệu nguồn dữ liệu, mô tả các thuộc tính và ý nghĩa lâm sàng của từng biến, các bước tiền xử lý bao gồm xử lý giá trị thiếu, dữ liệu trùng lặp,

ngoại lai, chuyển đổi biến phân loại, chuẩn hóa dữ liệu và kiểm tra chất lượng dữ liệu sau khi xử lý.

Chương 4: Trực quan hóa trình bày các biểu đồ khám phá dữ liệu như heatmap ma trận tương quan, biểu đồ phân bố của các biến số, biểu đồ so sánh giữa giá trị dự đoán và giá trị thực tế, cùng với biểu đồ thể hiện mức độ quan trọng của các đặc trưng (Feature Importance).

Chương 5: Xây dựng mô hình mô tả quy trình xây dựng và huấn luyện ba mô hình Hồi quy Logistic, SVM và KNN trên tập dữ liệu đã được chuẩn bị.

Chương 6: Thực nghiệm trình bày kết quả đánh giá hiệu suất của từng mô hình dựa trên các chỉ số đánh giá và ma trận nhầm lẫn, đồng thời so sánh và đề xuất mô hình tốt nhất cho bài toán dự đoán bệnh tim.

Chương 7: Kết luận và hướng phát triển tóm tắt những kết quả đạt được, nêu ra những hạn chế của đồ án và đề xuất hướng phát triển trong tương lai như mở rộng dữ liệu, thử nghiệm thêm các thuật toán khác hoặc tích hợp mô hình vào hệ thống hỗ trợ chẩn đoán y tế.

CHƯƠNG 2. CƠ SỞ LÝ THUYẾT

2.1. Tổng quan về bệnh tim

2.1.1. Khái niệm

Bệnh tim là nhóm các bệnh lý ảnh hưởng đến cấu trúc và chức năng của tim, làm suy giảm khả năng bơm máu đi nuôi cơ thể. Đây là một trong những nguyên nhân gây tử vong hàng đầu trên thế giới. Một số bệnh tim phổ biến bao gồm bệnh động mạch vành, suy tim, rối loạn nhịp tim và bệnh van tim.

2.1.2. Các yếu tố nguy cơ mắc bệnh tim

Tuổi tác, giới tính, tăng huyết áp, cholesterol cao, đái tháo đường, béo phì, hút thuốc lá, lạm dụng rượu bia, ít vận động, chế độ ăn uống không lành mạnh, căng thẳng kéo dài và tiền sử gia đình mắc bệnh tim. Những yếu tố này làm tăng khả năng mắc các bệnh tim mạch và được sử dụng làm cơ sở để dự đoán nguy cơ bệnh tim bằng Machine Learning.

2.2. Tổng quan về bài toán phân loại nhị phân

2.2.1. Khái niệm về bài toán phân loại nhị phân

Trong lĩnh vực truy xuất và truy hồi thông tin, bài toán phân loại nhị phân là bài toán dự đoán một đối tượng thuộc một trong hai lớp - đây là một bài toán cơ bản trong học máy, nhằm phân nhóm các đối tượng vào các danh mục xác định trước.

Bài toán phân loại nhị phân là một dạng của Supervised Learning (học có giám sát), tức là thuật toán được huấn luyện trên tập dữ liệu có nhãn, trong đó mỗi điểm dữ liệu được gán với một trong hai kết quả có thể xảy ra, thường là lớp “dương tính” và lớp “âm tính”. Mục tiêu chính là để thuật toán học được một ranh giới quyết định phân tách hai lớp dựa trên các đặc trưng đầu vào. [1]

Biến mục tiêu (target) chỉ nhận hai giá trị, thường được mã hóa thành: 0 và 1, Yes và No, True và False, hoặc Positive và Negative.

Quy trình xử lý bài toán phân loại nhị phân bao gồm:

Thu thập dữ liệu → Tiền xử lý dữ liệu → Huấn luyện mô hình → Đánh giá mô hình.

2.2.2. Chiến lược chuyển đổi bài toán phân loại đa nhãn

Phương pháp chuyển đổi bài toán là chuyển đổi bài toán phân loại đa nhãn thành các bài toán phân loại khác, sau đó sử dụng các phương pháp học để xử lý. Ưu điểm của phương

pháp này là sau khi chuyển đổi, có thể tận dụng trực tiếp các thuật toán học có giám sát đã được phát triển sẵn và kiểm chứng tốt. Hiện nay, có ba thuật toán học đa nhãn phổ biến dựa trên chiến lược chuyển đổi.

Chuyển đổi thành bài toán phân loại nhị phân là phương pháp cổ điển dựa trên chiến lược phân loại nhị phân. Phương pháp này chủ yếu chuyển đổi bài toán học phân loại đa nhãn thành L bài toán phân loại nhị phân, tức là mỗi nhãn danh mục tương ứng với một bài toán phân loại. Phương pháp BR sử dụng M thuật toán phân loại nhị phân để dự đoán; mỗi bộ phân loại có thể sử dụng bất kỳ phương pháp nào hiện có.

Chuyển đổi thành bài toán xếp hạng nhãn: Một số học giả đã chuyển đổi bài toán phân loại đa nhãn thành bài toán xếp hạng nhãn. Thuật toán Xếp hạng Nhãn (LR) là một phương pháp chuyển đổi bài toán được sử dụng rộng rãi, áp dụng phương pháp so sánh và sắp xếp nhãn theo từng cặp. Trong LR, cần huấn luyện $L(L-1)$ bộ phân loại nhị phân, trong đó L là số lượng nhãn, tức là huấn luyện một bộ phân loại cho mỗi cặp nhãn (L_i, L_j) . Đầu tiên, tập dữ liệu tương ứng với mỗi cặp nhãn được xác định, sau đó một bộ phân loại nhị phân được huấn luyện cho mỗi cặp nhãn, giá trị dự đoán của mỗi bộ phân loại được xuất ra, và kết quả được bỏ phiếu và sắp xếp.

Chuyển đổi thành bài toán phân loại đa lớp: Phương pháp Tập hợp Nhãn (LP) coi mỗi tổ hợp nhãn trong tập huấn luyện là một nhãn mới, từ đó chuyển dữ liệu đa nhãn thành dữ liệu đơn nhãn để phân loại. Ưu điểm của LP là có xét đến mối tương quan giữa các nhãn, tuy nhiên nhược điểm là không thể dự đoán các tổ hợp nhãn chưa xuất hiện trong tập huấn luyện, dễ gây mất cân bằng lớp, và chi phí tính toán tăng nhanh khi số lượng nhãn lớn. [2]

2.2.3. Các thách thức chính của bài toán phân loại nhị phân

Đối với bài toán phân loại tuyến tính, SVM là phương pháp tối ưu. Tuy nhiên, đa số bài toán thực tế là phi tuyến nên cần kết hợp kernel function. Việc lựa chọn kernel chủ yếu dựa trên kinh nghiệm và chưa đảm bảo tối ưu. Bên cạnh đó, thiết kế hàm mục tiêu cho bài toán phi tuyến vẫn là thách thức, vì khoảng cách Euclidean chỉ phản ánh mối quan hệ cục bộ giữa các điểm gần nhất. Một hướng tiếp cận mới là tối ưu dựa trên vùng không gian giữa hai ranh giới phân lớp kết hợp với phân phối dữ liệu $p(x)$, nhưng làm tăng độ phức tạp của

bài toán do phải tối ưu nhiều ẩn số và chưa có bằng chứng về tính duy nhất cũng như sự tồn tại của nghiệm tối ưu. [3]

2.3. Tổng quan về tiền xử lý dữ liệu

2.3.1. Khái niệm tiền xử lý dữ liệu

Tiền xử lý dữ liệu (Data Preprocessing) là bước đầu tiên trong quy trình phân tích dữ liệu và xây dựng mô hình học máy (Machine Learning). Đây là quá trình xử lý, làm sạch và biến đổi dữ liệu thô (raw data) thành dạng dữ liệu có cấu trúc, nhất quán và phù hợp để các thuật toán có thể tiến hành phân tích hoặc huấn luyện mô hình.

Khái niệm này gắn liền với việc nâng cao chất lượng, độ chính xác và tính toàn vẹn của dữ liệu. Tiền xử lý dữ liệu đóng vai trò quan trọng trong việc thu hẹp khoảng cách giữa dữ liệu thô được thu thập từ thực tế và dữ liệu đầu vào mà các hệ thống phân tích hoặc mô hình học máy yêu cầu. Một quy trình tiền xử lý hiệu quả sẽ giúp cải thiện chất lượng dữ liệu đầu vào, từ đó nâng cao hiệu suất và độ chính xác của kết quả dự đoán.

Trong thực tế, dữ liệu thường tồn tại nhiều vấn đề như giá trị thiếu (Missing Values), dữ liệu trùng lặp (Duplicate Data), dữ liệu ngoại lệ (Outliers) hoặc sự không nhất quán về định dạng dữ liệu. Do đó, trong đề tài dự đoán nguy cơ mắc bệnh tim bằng các mô hình Machine Learning, việc tiền xử lý dữ liệu giúp đảm bảo bộ dữ liệu y tế được làm sạch và chuẩn hóa trước khi đưa vào quá trình huấn luyện mô hình [4]

2.3.2. Mục đích của tiền xử lý dữ liệu

Mục đích của tiền xử lý dữ liệu là chuẩn bị và chuyển đổi dữ liệu thô thành dạng dữ liệu sạch, có cấu trúc và phù hợp để các thuật toán phân tích dữ liệu và mô hình học máy có thể xử lý một cách hiệu quả. Đây là bước quan trọng giúp nâng cao chất lượng dữ liệu đầu vào và tạo nền tảng cho việc xây dựng các mô hình dự đoán có độ chính xác cao.

Cụ thể, quá trình tiền xử lý dữ liệu hướng đến các mục tiêu sau:

Cải thiện chất lượng dữ liệu: Tiền xử lý dữ liệu giúp phát hiện và khắc phục các vấn đề giá trị thiếu, dữ liệu trùng lặp, dữ liệu ngoại lệ hoặc các sai sót, từ đó nâng cao tính chính xác, tính đầy đủ và tính nhất quán của dữ liệu. Một tập dữ liệu có chất lượng tốt sẽ giúp hạn chế các sai lệch trong quá trình phân tích và dự đoán.

Chuẩn hóa dữ liệu đầu vào: Các thuộc tính trong bộ dữ liệu thường có đơn vị đo lường và phạm vi giá trị khác nhau. Việc chuẩn hóa dữ liệu giúp đưa các thuộc tính về cùng thang đo, đồng thời chuyển đổi các biến phân loại sang dạng dữ liệu phù hợp để các thuật toán học máy có thể xử lý hiệu quả hơn.

Nâng cao độ chính xác của mô hình: Hiệu suất của mô hình học máy phụ thuộc rất lớn vào chất lượng dữ liệu đầu vào. Dữ liệu được làm sạch và chuẩn hóa giúp mô hình học được các đặc trưng có ý nghĩa, giảm ảnh hưởng của nhiễu dữ liệu và cải thiện khả năng dự đoán trên dữ liệu mới.

Giảm độ phức tạp của dữ liệu: Thông qua việc loại bỏ các thuộc tính dư thừa, xử lý dữ liệu không cần thiết hoặc lựa chọn các đặc trưng phù hợp, quá trình tiền xử lý giúp giảm độ phức tạp của tập dữ liệu. Điều này góp phần giảm thời gian huấn luyện và tối ưu tài nguyên tính toán.

Tăng tính nhất quán và khả năng tích hợp dữ liệu: Khi dữ liệu được chuẩn hóa về định dạng và cấu trúc, việc kết hợp dữ liệu từ nhiều nguồn khác nhau trở nên dễ dàng hơn. Điều này đặc biệt quan trọng trong các hệ thống phân tích dữ liệu lớn và các ứng dụng học máy thực tế.

Đối với đề tài dự đoán nguy cơ mắc bệnh tim bằng các mô hình Machine Learning, quá trình tiền xử lý dữ liệu giúp đảm bảo bộ dữ liệu y tế được làm sạch và chuẩn hóa trước khi đưa vào huấn luyện. Nhờ đó, các mô hình có thể học được những đặc trưng quan trọng liên quan đến nguy cơ mắc bệnh tim và đưa ra các dự đoán đáng tin cậy hơn. [5]

2.3.3. Các kỹ thuật tiền xử lý dữ liệu

Trước khi xây dựng mô hình dự đoán nguy cơ mắc bệnh tim, bộ dữ liệu cần được khám phá và xử lý nhằm phát hiện các vấn đề có thể ảnh hưởng đến chất lượng phân tích. Quá trình tiền xử lý dữ liệu không chỉ giúp nâng cao chất lượng dữ liệu đầu vào mà còn góp phần cải thiện độ chính xác và khả năng tổng quát hóa của mô hình học máy.

Khám phá dữ liệu ban đầu (Exploratory Data Analysis - EDA) được thực hiện nhằm tìm hiểu cấu trúc dữ liệu, kiểu dữ liệu của từng thuộc tính, phân bố dữ liệu và các đặc điểm nổi bật của tập dữ liệu. Đây là bước quan trọng giúp xác định những vấn đề cần được xử lý trước khi tiến hành huấn luyện mô hình.

Làm sạch dữ liệu (Data Cleaning) tập trung vào việc phát hiện và xử lý các giá trị thiếu (Missing Values) cũng như các bản ghi trùng lặp (Duplicate Data). Trong thực tế, dữ liệu thu thập được thường không hoàn chỉnh do lỗi nhập liệu hoặc thiếu thông tin từ đối tượng khảo sát. Việc xử lý dữ liệu thiếu và loại bỏ dữ liệu trùng lặp giúp nâng cao tính chính xác, tính nhất quán và độ tin cậy của dữ liệu đầu vào.

Phát hiện và xử lý ngoại lệ (Outlier Detection & Handling) là quá trình xác định các giá trị có sự khác biệt đáng kể so với phần lớn dữ liệu còn lại. Việc phát hiện và xử lý các ngoại lệ giúp đảm bảo tập dữ liệu phản ánh chính xác đặc điểm của bài toán nghiên cứu. Các ngoại lệ thường được nhận diện thông qua các kỹ thuật phân tích dữ liệu khám phá kết hợp với các công cụ trực quan hóa như biểu đồ hộp (Boxplot) hoặc biểu đồ phân bố (Histogram).

Chuyển đổi kiểu dữ liệu (Data Type Conversion & Transformation) đưa dữ liệu về định dạng phù hợp và nhất quán để thuận tiện cho việc phân tích và xây dựng mô hình. Quá trình này có thể bao gồm việc chuyển đổi kiểu dữ liệu, chuẩn hóa đơn vị đo lường hoặc biến đổi dữ liệu theo yêu cầu của bài toán.

Mã hóa biến phân loại (Categorical Variable Encoding) được thực hiện nhằm chuyển đổi các thuộc tính dạng phân loại sang dạng số để các thuật toán học máy có thể xử lý. Hai phương pháp mã hóa phổ biến thường được sử dụng là Label Encoding và One-Hot Encoding.

Chuẩn hóa dữ liệu (Data Normalization & Scaling) giúp đưa các thuộc tính về cùng một thang đo nhằm hạn chế sự chênh lệch quá lớn giữa các biến đầu vào. Điều này giúp các thuật toán học máy hoạt động ổn định hơn và nâng cao hiệu quả dự đoán. Hai phương pháp chuẩn hóa được sử dụng phổ biến là Min-Max Scaling và Z-Score Normalization.

Chia tập dữ liệu huấn luyện và kiểm tra (Data Splitting) là bước cuối cùng trước khi xây dựng mô hình học máy. Dữ liệu được phân chia thành các tập khác nhau nhằm đánh giá khả năng dự đoán của mô hình trên những dữ liệu chưa từng xuất hiện trước đó, đồng thời hạn chế hiện tượng quá khớp (Overfitting).

Sau khi hoàn thành các bước tiền xử lý, bộ dữ liệu đã được làm sạch, chuẩn hóa và chuyển đổi về định dạng phù hợp. Đây là cơ sở quan trọng để tiến hành xây dựng và đánh giá các mô hình Machine Learning trong bài toán dự đoán nguy cơ mắc bệnh tim. [6]

2.4. Tổng quan về Machine Learning

2.4.1. Khái niệm

Machine Learning (ML), hay học máy, là một nhánh cơ bản của trí tuệ nhân tạo (Artificial Intelligence – AI), tập trung vào việc phát triển các thuật toán và mô hình cho phép hệ thống máy tính học hỏi từ dữ liệu mà không cần được lập trình một cách tường minh cho từng tác vụ cụ thể.

Theo định nghĩa kinh điển của Arthur Samuel (1959): "Machine Learning là lĩnh vực nghiên cứu giúp máy tính có khả năng học mà không cần được lập trình một cách rõ ràng." Một định nghĩa khác có tính hình thức hơn do Tom Mitchell đề xuất: "Một chương trình máy tính được cho là học từ kinh nghiệm E với một lớp nhiệm vụ T và độ đo hiệu năng P, nếu hiệu năng của nó tại các nhiệm vụ T, đo bởi P, cải thiện theo kinh nghiệm E." [7]

Về bản chất, quá trình học máy bao gồm ba thành phần chính:

Dữ liệu (Data): Đầu vào thô, có thể có nhãn hoặc không nhãn.

Mô hình (Model): Hàm số hoặc cấu trúc thống kê được sử dụng để dự đoán hoặc phát hiện quy luật.

Thuật toán huấn luyện (Training algorithm): Quy trình điều chỉnh các tham số của mô hình nhằm tối ưu hóa độ đo hiệu năng dựa trên dữ liệu.

Machine Learning khác biệt với lập trình truyền thống ở chỗ: thay vì viết luật lệ (rule-based) một cách thủ công, hệ thống tự động phát hiện ra các quy tắc ẩn từ dữ liệu đầu vào và đầu ra mong muốn. [8]

2.4.2. Vai trò

Machine Learning đóng vai trò then chốt trong cuộc cách mạng công nghiệp lần thứ tư (Industry 4.0) và sự phát triển của khoa học dữ liệu. Các vai trò chính bao gồm:

Xử lý và khai phá dữ liệu quy mô lớn: Trong bối cảnh bùng nổ dữ liệu (Big Data), Machine Learning cung cấp khả năng tự động phát hiện các mẫu hình, xu hướng và tương

quan phức tạp mà con người hoặc các phương pháp thống kê truyền thống khó có thể thực hiện trong thời gian hợp lý.

Tự động hóa ra quyết định thông minh: Machine Learning cho phép các hệ thống đưa ra dự báo hoặc quyết định dựa trên bằng chứng từ dữ liệu lịch sử, thay vì các quy tắc cứng nhắc. Ví dụ: chấm điểm tín dụng, dự báo nhu cầu tồn kho, phát hiện gian lận.

Cá nhân hóa trải nghiệm người dùng: Các hệ thống khuyến nghị trong thương mại điện tử, nội dung số, quảng cáo trực tuyến sử dụng Machine Learning để thích ứng hành vi với từng cá nhân dựa trên lịch sử tương tác.

Nâng cao khả năng của các hệ thống tự trị: Machine Learning là nền tảng cho các công nghệ như xe tự lái, robot thông minh, giám sát công nghiệp không người lái – nơi hệ thống phải liên tục học và thích nghi với môi trường thay đổi.

Tối ưu hóa và nhận dạng: Machine Learning vượt trội trong các bài toán nhận dạng mẫu (pattern recognition) như nhận dạng giọng nói, chữ viết tay, khuôn mặt, và tối ưu hóa các quy trình phức tạp như điều phối giao thông, phân bổ tài nguyên mạng.

Nhìn chung, vai trò cốt lõi của Machine Learning là chuyển dữ liệu thành tri thức hoặc hành động tối ưu một cách tự động và có khả năng thích nghi. [8]

2.4.3. Các lĩnh vực ứng dụng

Machine Learning đã thâm nhập vào hầu hết các ngành khoa học – kỹ thuật và kinh tế - xã hội. Dưới đây là các lĩnh vực điển hình:

Lĩnh vực Kinh tế, Thương mại và Quản trị hệ thống

Đối với lĩnh vực *Kinh tế - Tài chính*, các mô hình học máy được sử dụng để xây dựng hệ thống chấm điểm tín dụng, tự động nhận diện giao dịch gian lận, dự báo biến động chứng khoán và vận hành thị trường giao dịch tần suất cao. Trong *Sản xuất công nghiệp*, hỗ trợ thiết lập hệ thống bảo trì dự đoán nhằm giảm thiểu hư hỏng thiết bị, kết hợp thị giác máy để kiểm định chất lượng sản phẩm và tối ưu hóa chuỗi cung ứng. Đối với *Thương mại điện tử & Marketing*, công nghệ này tạo ra các hệ thống gợi ý cá nhân hóa (như giải pháp của Amazon, Netflix), hỗ trợ phân cụm khách hàng mục tiêu và dự báo chính xác tỷ lệ rời bỏ dịch vụ.

Lĩnh vực Kỹ thuật, Hạ tầng và An toàn thông tin

Trên phương diện hạ tầng kỹ thuật, Machine Learning là nền tảng cốt lõi để thúc đẩy tính tự động hóa và nâng cao độ an toàn hệ thống. Trong *Giao thông vận tải*, các thuật toán học máy trực tiếp vận hành hệ thống xe tự hành, điều phối giao thông thông minh thông qua dự báo ùn tắc và tối ưu hóa lộ trình theo thời gian thực. Nhằm bảo vệ các hạ tầng số, lĩnh vực *An ninh mạng & An toàn thông tin* ứng dụng Machine Learning để triển khai hệ thống phát hiện xâm nhập trái phép (IDS), tự động phân tích hành vi của mã độc và phát hiện các biểu hiện bất thường trên toàn mạng lưới mạng.

Lĩnh vực Y sinh và các Công nghệ tương tác thông minh

Trong khoa học sức khỏe và tương tác người - máy, ML mang lại những đột phá mang tính định lượng cao. Lĩnh vực *Y tế - Sinh học* ứng dụng các mô hình học sâu để phân tích ảnh y khoa (X-quang, MRI, CT) giúp phát hiện sớm ung thư, đồng thời hỗ trợ phân tích bản đồ gen và tăng tốc quy trình thử nghiệm thuốc mới. Đóng góp vào sự phát triển này là hai nhánh công nghệ nền tảng: *Thị giác máy tính* (chịu trách nhiệm nhận dạng khuôn mặt, phân tích vật thể và giám sát an ninh) và *Xử lý ngôn ngữ tự nhiên - NLP* (vận hành hệ thống trợ lý ảo, chatbot, dịch thuật và tự động tóm tắt văn bản).

Ngoài ra, Machine Learning còn được ứng dụng mạnh mẽ trong nông nghiệp chính xác (dự báo năng suất, phát hiện sâu bệnh), năng lượng (dự báo phụ tải điện, tối ưu lưới điện thông minh), giáo dục (đề xuất nội dung học tập thích ứng) và nhiều lĩnh vực khác.[9]

2.4.4. Phân loại

Học có giám sát (Supervised Learning)

Định nghĩa

Học có giám sát là một kỹ thuật học máy sử dụng các tập dữ liệu đã được gán nhãn (labeled data) để huấn luyện các mô hình trí tuệ nhân tạo nhận diện các mẫu hình và mối quan hệ ẩn bên trong dữ liệu.

Cơ chế hoạt động

Quy trình của học có giám sát bắt đầu bằng việc chuẩn bị tập dữ liệu huấn luyện đã được gán nhãn chính xác để mô hình học cách thiết lập mối quan hệ giữa đặc trưng và kết quả. Trong quá trình này, mô hình liên tục đưa ra dự đoán và sử dụng hàm mất mát để đo lường sai số so với thực tế, sau đó áp dụng các thuật toán tối ưu hóa như gradient descent

để điều chỉnh các tham số nhằm giảm thiểu sai số đó. Cuối cùng, hiệu suất của mô hình được kiểm chứng bằng dữ liệu thử nghiệm độc lập để đảm bảo khả năng dự đoán chính xác và tính tổng quát hóa trên các dữ liệu mới trong thực tế. [10]

Học không giám sát (Unsupervised Learning)

Định nghĩa

Học không giám sát là một nhánh của máy học sử dụng các thuật toán để phân tích và gom cụm các tập dữ liệu chưa được gán nhãn (unlabeled data). Các thuật toán này có khả năng tự khám phá các mẫu hình ẩn hoặc các nhóm dữ liệu mà không cần sự can thiệp hay hướng dẫn của con người.

Cơ chế hoạt động

Hoạt động bằng cách tìm kiếm các điểm tương đồng và khác biệt trong thông tin đầu vào. Xác định các cấu trúc hoặc mẫu hình tự nhiên bên trong dữ liệu thô. Trong các mô hình xác suất (như GMM), nó giả định sự tồn tại của các biến ẩn (latent variables) để phân loại dữ liệu. [10]

Học bán giám sát (Semi-supervised Learning)

Học bán giám sát là một nhánh của học máy kết hợp giữa học có giám sát và học không giám sát bằng cách sử dụng cả dữ liệu đã gán nhãn (labeled data) và dữ liệu chưa gán nhãn (unlabeled data) để huấn luyện các mô hình cho các tác vụ phân loại và hồi quy. Phương pháp này đặc biệt hữu ích khi việc thu thập dữ liệu có nhãn quá tốn kém hoặc khó khăn, trong khi dữ liệu chưa có nhãn lại rất dồi dào và dễ tìm kiếm. [10]

Học tăng cường (Reinforcement Learning)

Định nghĩa

Học tăng cường là quá trình mà các tác nhân tự hành (autonomous agents) học cách đưa ra quyết định tối ưu bằng cách tương tác trực tiếp với một môi trường không chắc chắn. Không giống như học có giám sát dựa trên dữ liệu gán nhãn sẵn, Reinforcement Learning học thông qua kinh nghiệm thực tế.

Cơ chế hoạt động

Trong học tăng cường (Reinforcement Learning), tác nhân học cách ra quyết định thông qua quá trình thử và sai: nó thực hiện các hành động trong môi trường và nhận lại

phản hồi dưới dạng phần thưởng (để củng cố hành động đúng) hoặc hình phạt (để hạn chế hành động sai). Trong quá trình đó, tác nhân luôn phải duy trì sự cân bằng khéo léo giữa việc khai thác những chiến lược đã biết để thu lợi nhuận và việc khám phá những khả năng mới nhằm tìm kiếm những cơ hội nhận thưởng cao hơn trong tương lai. [10]

2.5. Các thuật toán sử dụng

2.5.1. Support Vector Machine (SVM)

Khái niệm

SVM là một thuật toán học máy có giám sát (supervised learning), được sử dụng chủ yếu cho các bài toán phân loại (classification). Mục tiêu của thuật toán là tìm ra một ranh giới (biên giới) tốt nhất để phân chia các tập dữ liệu khác nhau thành các lớp riêng biệt. [7]


Cơ chế hoạt động

Tìm siêu phẳng tối ưu (Hyperplane): SVM biểu diễn các điểm dữ liệu trong không gian n chiều. Sau đó, nó tìm kiếm một siêu phẳng (có thể hiểu đơn giản là một đường thẳng hoặc một mặt phẳng) để phân tách các lớp dữ liệu.

Tối đa hóa lề (Margin): "Lề" là khoảng cách giữa siêu phẳng đến các điểm dữ liệu gần nhất của mỗi lớp. SVM luôn cố gắng cực đại hóa khoảng cách lề này để giảm thiểu việc phân lớp sai đối với các điểm dữ liệu mới.

Sử dụng hàm nhân (Kernel Function): Đối với các dữ liệu phức tạp không thể phân tách bằng một đường thẳng đơn giản (phi tuyến tính), SVM sử dụng các hàm nhân (như RBF, Polynomial, hoặc Sigmoid). Các hàm này giúp biến đổi dữ liệu sang một không gian nhiều chiều hơn, nơi mà một bề mặt quyết định phi tuyến có thể trở thành một phương trình tuyến tính để phân tách các lớp.

Xử lý dữ liệu không cân bằng: Thuật toán có tham số như *class_weight* để hỗ trợ xử lý hiệu quả các tập dữ liệu có sự chênh lệch lớn về số lượng mẫu giữa các lớp. [7], [11]



Ưu và nhược điểm

Thuật toán SVM là một công cụ mạnh mẽ trong việc xử lý dữ liệu có số chiều lớn (như phân loại văn bản) và tiết kiệm bộ nhớ nhờ cơ chế chỉ sử dụng một tập hợp con các điểm dữ liệu quan trọng (Support Vectors). Nó mang lại sự linh hoạt cao khi có thể xử lý cả dữ liệu tuyến tính và phi tuyến tính thông qua kỹ thuật hàm nhân (Kernel trick), đồng thời có khả năng bỏ qua các điểm ngoại lệ để tìm ra biên giới phân lớp tối ưu. Tuy nhiên, SVM vẫn tồn tại một số hạn chế như kém hiệu quả khi dữ liệu bị nhiễu hoặc khi số lượng thuộc tính lớn hơn nhiều so với số lượng mẫu, thiếu tính giải thích về xác suất cho các kết quả phân loại, và hiệu suất của mô hình phụ thuộc rất lớn vào việc lựa chọn chính xác các tham số cũng như loại hàm nhân phù hợp.

2.5.2. K - Nearest Neighbors (KNN)

Khái niệm

K-Nearest Neighbors (KNN) là một thuật toán học máy có giám sát dựa trên khoảng cách (instance-based learning), thuộc nhóm phương pháp học lười (lazy learning). Đặc trưng của thuật toán này là không trải qua giai đoạn xây dựng một mô hình toán học tường minh trong quá trình huấn luyện, mà thay vào đó, nó lưu trữ toàn bộ dữ liệu huấn luyện và chỉ thực hiện tính toán khi xuất hiện yêu cầu dự đoán dữ liệu mới.

Cơ chế hoạt động


Cơ chế thực thi của thuật toán KNN được triển khai thông qua các giai đoạn sau:

Bước 1 – Lưu trữ dữ liệu: Trong giai đoạn huấn luyện, thuật toán không thực hiện các phép toán phức tạp mà chỉ tiến hành ghi nhớ và lưu trữ lại toàn bộ các vector đặc trưng cùng nhãn tương ứng của tập huấn luyện.

Bước 2 – Tính toán khoảng cách: Khi xuất hiện một mẫu dữ liệu kiểm thử x mới, thuật toán sẽ tính toán khoảng cách hình học từ điểm x này đến tất cả các điểm dữ liệu đã được lưu trữ trong hệ thống, phổ biến nhất là sử dụng công thức khoảng cách Euclidean.

Bước 3 – Xác định láng giềng: Mô hình tiến hành sắp xếp các kết quả và lọc ra một số lượng K mẫu dữ liệu có khoảng cách ngắn nhất (gần nhất) đối với mẫu x .

Bước 4 – Gán nhãn dự đoán: Đối với tác vụ phân lớp, thuật toán gán cho x nhãn của lớp chiếm đa số trong số K láng giềng; đối với tác vụ hồi quy, giá trị dự đoán thu được bằng cách tính trung bình cộng giá trị mục tiêu của K láng giềng đó.



Điều kiện bắt buộc: Dữ liệu phải được chuẩn hóa trước khi tính khoảng cách, vì nếu không, đặc trưng có miền giá trị lớn sẽ lấn át các đặc trưng khác.

KNN dự đoán dựa trên giả định rằng các mẫu gần nhau trong không gian đặc trưng thì có xu hướng cùng nhãn. Mọi tính toán đều dồn vào giai đoạn dự đoán, nên càng nhiều dữ liệu thì càng chậm. [12]

Ưu và nhược điểm

K-Nearest Neighbors (KNN) là thuật toán đơn giản dựa trên giả định rằng các điểm dữ liệu gần nhau trong không gian đặc trưng thường cùng một nhãn. Dù dễ triển khai và trực quan, KNN có nhược điểm lớn là hiệu suất giảm mạnh khi dữ liệu tăng trưởng do mọi tính toán đều dồn vào lúc dự đoán, gây tốn bộ nhớ và chậm tốc độ xử lý. Bên cạnh đó, thuật toán này rất nhạy cảm với nhiễu và yêu cầu bắt buộc phải chuẩn hóa dữ liệu để tránh việc các đặc trưng có giá trị lớn gây sai lệch kết quả.

2.5.3. Logistic Regression

Khái niệm

Logistic Regression là một thuật toán học máy được sử dụng chủ yếu cho các bài toán phân loại nhị phân, tức là bài toán trong đó biến mục tiêu có hai giá trị có thể có (thường là 0 hoặc 1, true hoặc false, có hoặc không). Mặc dù tên của nó bao gồm từ “hồi quy” (regression), nhưng Logistic Regression thực chất là một mô hình phân loại.

Cơ chế hoạt động

Cơ chế thực thi của thuật toán Logistic Regression được triển khai thông qua các giai đoạn sau:

Bước 1: Tính toán giá trị tuyến tính tương tự như hồi quy tuyến tính, mô hình bắt đầu bằng việc tính toán một giá trị dựa trên sự kết hợp của các biến đầu vào. Tuy nhiên, đầu ra của bước này có thể kéo dài từ âm vô cùng đến dương vô cùng.

Bước 2: Để chuyển đổi giá trị vô hạn thành một xác suất hữu hạn, thuật toán sử dụng ánh xạ thông qua hàm Sigmoid. Hàm này có đồ thị hình chữ S và được định nghĩa bằng công thức:

$$\sigma(t) = \frac{1}{1 + e^{-t}}$$


Mọi giá trị thực đưa vào hàm này đều sẽ được đưa về khoảng (0,1).

Bước 3: Xử lý ngoại lai (Outliers) Nhờ đặc tính của đường cong chữ S, khi gặp các giá trị cực lớn hoặc cực nhỏ (điểm ngoại lai), hàm Sigmoid sẽ tiến sát về 1 hoặc 0 thay vì làm thay đổi hoàn toàn đường biên quyết định như trong hồi quy tuyến tính. Điều này giúp mô hình ổn định và chính xác hơn trong phân loại.

Bước 4: Quyết định phân lớp dựa trên ngưỡng (Threshold) Sau khi có xác suất từ hàm Sigmoid, mô hình sẽ áp dụng một ngưỡng quyết định (thông thường là 0.5) để phân loại:

Nếu xác suất ≥ 0.5 : Dữ liệu được xếp vào lớp dương tính (Positive Class/1).

Nếu xác suất < 0.5 : Dữ liệu được xếp vào lớp âm tính (Negative Class/0). [13]



Ưu và nhược điểm

Hồi quy Logistic là thuật toán phân loại nhị phân phổ biến, nổi bật với ưu điểm dễ hiểu, tốc độ xử lý nhanh và khả năng trả về kết quả dưới dạng xác suất (từ 0 đến 1) thay vì chỉ là nhãn lớp đơn thuần. Khác với hồi quy tuyến tính, nó xử lý dữ liệu ngoại lai hiệu quả hơn nhờ sử dụng hàm Sigmoid. Tuy nhiên, mô hình này bị giới hạn bởi tính chất tuyến tính nên khó nắm bắt các mối quan hệ phức tạp, đồng thời hoạt động tốt nhất với hai lớp và kém linh hoạt hơn so với các thuật toán hiện đại khi đối mặt với dữ liệu nhiễu hoặc bài toán phân loại đa lớp.

2.6. Các chỉ số đánh giá mô hình

Accuracy (Độ chính xác): Tỷ lệ phần trăm các dự đoán đúng trên tổng số các trường hợp được dự đoán.

Sensitivity (Độ nhạy): Đo lường tỷ lệ các trường hợp thực tế là “Dương tính” mà mô hình dự đoán đúng.

Precision (Độ chuẩn xác): Chỉ số đo lường tỷ lệ các dự đoán dương tính (Positive) đúng trên tổng số tất cả các dự đoán dương tính mà mô hình đã đưa ra.

F1-score: Là trung bình điều hòa (harmonic mean) giữa Precision và Recall.

ROC-AUC: Đánh giá khả năng phân biệt giữa các lớp của mô hình bằng cách đo diện tích dưới đường cong ROC.

CHƯƠNG 3. DỮ LIỆU (DATA)

3.1. Giới thiệu bộ dữ liệu

Trong đề án này, nhóm sử dụng bộ dữ liệu Heart Disease Cleveland Dataset nhằm xây dựng mô hình dự đoán nguy cơ mắc bệnh tim dựa trên các thông tin lâm sàng và kết quả xét nghiệm của bệnh nhân. (Nguồn dataset: [HeartDiseasePredict](#)).

Bộ dữ liệu gồm 305 mẫu quan sát và 14 thuộc tính, trong đó bao gồm các thông tin về nhân khẩu học, triệu chứng lâm sàng, chỉ số sức khỏe và kết quả xét nghiệm liên quan đến bệnh tim mạch. Biến mục tiêu của bộ dữ liệu là target, được sử dụng để xác định tình trạng mắc bệnh tim của bệnh nhân.

Bộ dữ liệu được lựa chọn vì đây là một trong những bộ dữ liệu kinh điển trong lĩnh vực dự đoán bệnh tim, chứa nhiều đặc trưng có giá trị y học và phù hợp cho việc áp dụng các kỹ thuật tiền xử lý dữ liệu, phân tích dữ liệu cũng như xây dựng các mô hình Machine Learning nhằm hỗ trợ dự đoán nguy cơ mắc bệnh tim.

3.2. Mô tả các thuộc tính

Bộ dữ liệu bao gồm 14 thuộc tính mô tả các đặc điểm cá nhân, chỉ số sức khỏe và tình trạng bệnh lý của bệnh nhân. Các thuộc tính được sử dụng trong nghiên cứu bao gồm:

Age (Tuổi): Thể hiện tuổi của bệnh nhân. Tuổi là một trong những yếu tố quan trọng ảnh hưởng đến nguy cơ mắc bệnh tim mạch.

Sex (Giới tính): Biểu thị giới tính của bệnh nhân (Nam hoặc Nữ).

CP (Chest Pain Type): Mô tả loại đau ngực mà bệnh nhân gặp phải. Đây là một dấu hiệu lâm sàng quan trọng trong chẩn đoán bệnh tim.

Trestbps (Resting Blood Pressure): Huyết áp của bệnh nhân khi nghỉ ngơi, được đo bằng đơn vị mmHg.

Chol (Serum Cholesterol): Nồng độ cholesterol trong máu (mg/dl). Cholesterol cao có thể làm tăng nguy cơ mắc bệnh tim mạch.

FBS (Fasting Blood Sugar): Chỉ số đường huyết lúc đói của bệnh nhân, dùng để đánh giá nguy cơ rối loạn đường huyết và các bệnh liên quan.

Restecg (Resting Electrocardiographic Results): Kết quả điện tâm đồ lúc nghỉ, phản ánh hoạt động điện của tim.

Thalach (Maximum Heart Rate Achieved): Nhịp tim tối đa mà bệnh nhân đạt được trong quá trình kiểm tra.

Exang (Exercise Induced Angina): Cho biết bệnh nhân có xuất hiện đau thắt ngực khi vận động hay không.

Oldpeak: Độ chênh lệch đoạn ST trên điện tâm đồ khi vận động so với trạng thái nghỉ.

Slope: Độ dốc của đoạn ST trong kết quả điện tâm đồ, hỗ trợ đánh giá chức năng tim.

CA (Number of Major Vessels): Số lượng mạch máu lớn được quan sát thông qua phương pháp chẩn đoán hình ảnh.

Thal: Kết quả xét nghiệm Thalassemia, được sử dụng như một chỉ số hỗ trợ đánh giá nguy cơ bệnh tim.

Target: Biến mục tiêu của bộ dữ liệu. Thuộc tính này cho biết bệnh nhân thuộc nhóm Normal (không mắc bệnh tim) hoặc Risk Present (có nguy cơ/mắc bệnh tim). Đây là biến được sử dụng để huấn luyện và đánh giá các mô hình Machine Learning.

3.3. Phân tích Khám phá dữ liệu (EDA)

3.3.1. Tổng quan về bộ dữ liệu

Ta sử dụng các hàm *dim*, *head*, *str* để xem được số mẫu, thuộc tính và kiểu dữ liệu có trong dataset:

```
df <- read.csv("heart_cleveland_raw.csv")
dim(df)
```

```
## [1] 305 14
```

```
head(df)
```

```
##   age  sex      cp trestbps chol  fbs          restecg
## 1  69 Male Typical angina    160  234 TRUE Left ventricular hypertrophy
## 2  69 Female Typical angina    140  239 FALSE Normal
## 3  66 Female Typical angina    150  226 FALSE Normal
## 4  65 Male Typical angina    138  282 TRUE Left ventricular hypertrophy
## 5  64 Male Typical angina    110  211 FALSE Left ventricular hypertrophy
## 6  64 Male Typical angina    170  227 FALSE Left ventricular hypertrophy
##   thalach exang oldpeak      slope ca          thal      target
## 1   131    No     0.1      Flat  1      Normal      Normal
## 2   151    No     1.8    Upsloping  2      Normal      Normal
## 3   114    No     2.6 Downsloping  0      Normal      Normal
## 4   174    No     1.4      Flat  1      Normal Risk present
## 5   144   Yes     1.8      Flat  0      Normal      Normal
## 6   155    No     0.6      Flat  0 Reversible defect      Normal
```

```
str(df)
```

```
## 'data.frame': 305 obs. of 14 variables:
## $ age : int 69 69 66 65 64 64 63 61 60 59 ...
## $ sex : chr "Male" "Female" "Female" "Male" ...
## $ cp : chr "Typical angina" "Typical angina" "Typical angina" "Typical angina" ...
## $ trestbps: int 160 140 150 138 110 170 145 134 150 178 ...
## $ chol : int 234 239 226 282 211 227 233 234 240 270 ...
## $ fbs : logi TRUE FALSE FALSE TRUE FALSE FALSE ...
## $ restecg : chr "Left ventricular hypertrophy" "Normal" "Normal" "Left ventricular hypertrophy" ...
## $ thalach : int 131 151 114 174 144 155 150 145 171 145 ...
## $ exang : chr "No" "No" "No" "No" ...
## $ oldpeak : num 0.1 1.8 2.6 1.4 1.8 0.6 2.3 2.6 0.9 4.2 ...
## $ slope : chr "Flat" "Upsloping" "Downsloping" "Flat" ...
## $ ca : int 1 2 0 1 0 0 0 2 0 0 ...
## $ thal : chr "Normal" "Normal" "Normal" "Normal" ...
## $ target : chr "Normal" "Normal" "Normal" "Risk present" ...
```

Dữ liệu có 305 quan sát và 14 biến, kích thước phù hợp để xây dựng mô hình dự đoán nguy cơ bệnh tim. Các biến phân loại như *sex*, *cp*, *fbs*, *exang*, *slope*, *thal*, *target* đã được gán nhãn dạng chữ rõ ràng (ví dụ: "Male", "Asymptomatic", "Risk Present"), rất dễ hiểu và thuận tiện cho phân tích. Tuy nhiên, các biến này cần được chuyển sang kiểu factor trước khi thực hiện các bước xử lý tiếp theo.

Biến mục tiêu có tên là *target* với hai giá trị: "Risk Present" (có nguy cơ) và "Normal" (bình thường). Biến *thal* xuất hiện giá trị 7, cần được kiểm tra lại vì các giá trị thông thường chỉ là 3 hoặc 6. Nhìn chung, dữ liệu đã được làm sạch cơ bản về mặt định dạng, tạo điều kiện thuận lợi cho quá trình khám phá dữ liệu.

3.3.2. Thống kê mô tả

Ta sử dụng hàm `summary(df)` để thực hiện việc thống kê dữ liệu:

```
summary(df)
```

```
##      age      sex      cp      trestbps
##  Min.   :29.00  Length :305  Length :305  Min.    : 94.0
##  1st Qu.:48.00  N.unique : 2    N.unique : 4    1st Qu.:120.0
##  Median :56.00  N.blank  : 0    N.blank  : 0    Median :130.0
##  Mean   :54.58  Min.nchar: 4    Min.nchar:12    Mean   :134.7
##  3rd Qu.:61.00  Max.nchar: 6    Max.nchar:16    3rd Qu.:140.0
##  Max.    :77.00                      Max.    :999.0
##
##      chol      fbs      restecg      thalach
##  Min.   :126.0  Mode :logical Length :305  Min.    :-999.0
##  1st Qu.:211.8  FALSE:262  N.unique : 3    1st Qu.: 133.0
##  Median :243.0  TRUE :43   N.blank  : 0    Median : 152.0
##  Mean   :249.7                      Min.nchar: 6    Mean   : 145.8
##  3rd Qu.:276.2                      Max.nchar:28    3rd Qu.: 165.0
##  Max.    :999.0                      Max.    :202.0
##  NAs     :1
##      exang      oldpeak      slope      ca
##  Length :305  Min.    :0.000  Length :305  Min.    :0.0000
##  N.unique : 2  1st Qu.:0.000  N.unique : 3  1st Qu.:0.0000
##  N.blank  : 0  Median :0.800  N.blank  : 0  Median :0.0000
##  Min.nchar: 2  Mean   :1.043  Min.nchar: 4  Mean   :0.6656
##  Max.nchar: 3  3rd Qu.:1.600  Max.nchar:11  3rd Qu.:1.0000
##  Max.    :6.200                      Max.    :3.0000
##  NAs     :1
##      thal      target
##  Length :305  Length :305
##  N.unique : 3  N.unique : 2
##  N.blank  : 0  N.blank  : 0
##  Min.nchar: 6  Min.nchar: 6
##  Max.nchar:17  Max.nchar:12
##
##
```

Về biến số định lượng, độ tuổi của bệnh nhân dao động từ 29 đến 77 tuổi, với giá trị trung bình khoảng 54,6 tuổi và trung vị là 56 tuổi, cho thấy phân phối tương đối đối xứng. Huyết áp tâm thu khi nghỉ (trestbps) có giá trị trung bình 134,7 mmHg và trung vị 130 mmHg, nằm trong ngưỡng cao hơn bình thường. Cholesterol (chol) có giá trị tối thiểu 126 mg/dL và tối đa 999 mg/dL – một giá trị bất thường cần được kiểm tra lại vì mức cholesterol thực tế hiếm khi đạt đến 999 mg/dL, rất có thể đây là giá trị ngoại lai hoặc mã hóa cho dữ liệu thiếu. Nhịp tim tối đa (thalach) dao động từ 99 đến 202 nhịp/phút, với giá trị trung bình 145,8. Chỉ số oldpeak (chênh lệch ST) có giá trị trung bình 1,043, độ lệch chuẩn cho thấy dữ liệu phân tán đáng kể, đồng thời xuất hiện 1 giá trị NA cần được xử lý.

Về biến định tính, giới tính (sex) có 2 giá trị duy nhất, tương ứng với nam và nữ. Loại đau ngực (cp) có 4 loại khác nhau. Chỉ số đường huyết lúc đói (fbs) có 262 quan sát FALSE và 43 quan sát TRUE, cho thấy phần lớn bệnh nhân có đường huyết bình thường. Kết quả điện tâm đồ khi nghỉ (restecg) có 3 loại. Biến đau thắt ngực do gắng sức (exang) có 2 giá trị (Yes/No). Độ dốc ST (slope) có 3 loại. Số lượng mạch máu chính bị hẹp (ca)

dao động từ 0 đến 3 với giá trị trung bình 0,6656. Loại thalassemia (thal) có 3 loại khác nhau. Biến mục tiêu (target) có 2 giá trị duy nhất, thể hiện 2 trạng thái có nguy cơ và không có nguy cơ mắc bệnh tim, đồng thời không có giá trị NA hay trống.

Nhìn chung, dữ liệu có kích thước 303 mẫu sau khi loại bỏ 2 giá trị NA ở cột oldpeak và chol. Cần lưu ý xử lý giá trị 999, -999 và kiểm tra các điểm bất thường khác trước khi đưa vào mô hình.

3.3.3. Kiểm tra chất lượng dữ liệu

```
colSums(is.na(df))
```

##	age	sex	cp	trestbps	chol	fbs	restecg	thalach
##	0	0	0	0	1	0	0	0
##	exang	oldpeak	slope	ca	thal	target		
##	0	1	0	0	0	0		

Tổng cộng có 2 giá trị NA được phát hiện. Cụ thể, cột chol (cholesterol) có 1 giá trị thiếu và cột oldpeak có 1 giá trị thiếu. Các cột còn lại như age, sex, trestbps, fbs, restecg, thalach, exang, slope, ca, thal và target đều không có dữ liệu khuyết. Như vậy, tỷ lệ missing của toàn bộ dữ liệu là rất nhỏ, có thể xử lý bằng cách loại bỏ hoặc điền giá trị phù hợp.

Giá trị ngoại lai (outlier):

```
sapply(df[sapply(df, is.numeric)], function(x) sum(abs(x) >= 999, na.rm = TRUE))
```

##	age	trestbps	chol	thalach	oldpeak	ca
##	0	1	1	1	0	0

Về giá trị ngoại lai (outlier) với ngưỡng ≥ 999 hoặc ≤ -999 , kết quả cho thấy cột trestbps (huyết áp khi nghỉ) có 1 giá trị bất thường, cột chol (cholesterol) có 1 giá trị bất thường (cụ thể là 999 như đã thấy ở bảng thống kê mô tả), và cột thalach (nhịp tim tối đa) cũng có 1 giá trị nằm ngoài ngưỡng. Các cột age, oldpeak và ca không phát hiện outlier theo tiêu chí này. Những giá trị bất thường này cần được xử lý trước khi đưa vào mô hình để tránh ảnh hưởng đến kết quả dự đoán.

Dữ liệu trùng lặp

```
sum(duplicated(df))
```


```
## [1] 3
```

Phát hiện có 3 dòng dữ liệu bị trùng lặp hoàn toàn. Việc tồn tại các bản ghi trùng nhau có thể gây ra hiện tượng overfitting khi huấn luyện mô hình. Vì vậy, cần tiến hành loại bỏ các dòng trùng lặp này để đảm bảo tính khách quan và chính xác khi đánh giá mô hình.

3.3.4. Phân phối biến số

Để trực quan hóa phân phối của các biến số định lượng, nhóm đã sử dụng biểu đồ histogram (biểu đồ tần số). Lệnh `par(mfrow = c(3,4))` được dùng để chia lưới đồ họa thành 3 hàng và 4 cột, hiển thị đồng thời nhiều biểu đồ. Vòng lặp `for` duyệt qua tất cả các biến có kiểu số trong dữ liệu, sau đó vẽ histogram cho từng biến. Các biến được khảo sát bao gồm: *age*, *trestbps*, *chol*, *restecg*, *thalach*, *oldpeak*, *ca*, *thal*.

```
par(mfrow = c(3,4))
for(col in names(df[sapply(df, is.numeric)])) {
  hist(df[[col]], main = col, xlab = col, col = "steelblue")
}
```



Từ các biểu đồ histogram của các biến định lượng trong bộ dữ liệu, nhóm em đưa ra một số nhận xét về hình dạng phân phối của từng biến như sau:

age (tuổi): Biểu đồ cho thấy phân phối gần đối xứng, hơi lệch phải nhẹ, với tần số cao nhất tập trung trong khoảng 50–70 tuổi. Giá trị tuổi trải dài từ khoảng 30 đến 80, phù hợp với đặc điểm nhóm bệnh nhân trung niên và cao tuổi. Không xuất hiện giá trị bất thường sau khi làm sạch.

trestbps (huyết áp tâm thu khi nghỉ): Phân phối có dạng gần chuẩn, tập trung chủ yếu trong khoảng 120–140 mmHg. Tuy nhiên, biểu đồ cho thấy có một số giá trị cao bất thường ở phía đuôi bên phải (khoảng 180–200 mmHg) cần được xem xét.

chol (cholesterol): Phân phối lệch phải rõ rệt, phần lớn giá trị tập trung trong khoảng 150–400 mg/dL. Đặc biệt, biểu đồ xuất hiện một giá trị ngoại lai rất cao ở khoảng 600–1000 mg/dL. Giá trị này cần được xử lý trước khi đưa vào mô hình.

thalach (nhịp tim tối đa đạt được): Phân phối gần đối xứng, hơi lệch trái nhẹ, tập trung trong khoảng 120–170 nhịp/phút. Đa số bệnh nhân có nhịp tim ở mức trung bình đến khá khi gắng sức. Một vài giá trị thấp (khoảng 60–70) vẫn nằm trong giới hạn sinh lý bình thường.

oldpeak (độ chênh ST): Phân phối lệch phải mạnh, phần lớn giá trị tập trung ở vùng thấp (0–2), trong đó tần số cao nhất ở mức 0.0. Giá trị càng cao càng hiếm, nhưng có thể lên đến hơn 6.0. Biến này có độ phân tán lớn, phản ánh mức độ thiếu máu cơ tim khác nhau giữa các bệnh nhân.

ca (số lượng mạch máu chính bị hẹp): Đây là biến rời rạc với các giá trị 0, 1, 2, 3. Biểu đồ cho thấy phân phối lệch trái, đa số bệnh nhân có ca = 0, số bệnh nhân có ca = 1 thấp hơn, và ca = 2, 3 càng ít dần. Điều này hoàn toàn phù hợp với đặc điểm lâm sàng của bệnh tim trong quần thể nghiên cứu.

Sau khi làm sạch, các biến age và thalach có phân phối tương đối chuẩn, phù hợp cho các mô hình thống kê. Các biến chol, oldpeak và ca có phân phối lệch, cần cân nhắc các phương pháp chuẩn hóa hoặc biến đổi phù hợp. Đặc biệt, giá trị ngoại lai ở biến chol cần được xử lý triệt để trước khi huấn luyện mô hình.

3.3.5. Quan hệ với các biến

Để đánh giá mối liên hệ giữa từng biến số với tình trạng bệnh tim, chúng tôi thực hiện hai bước. Đầu tiên, kiểm tra sự cân bằng của biến mục tiêu *target* bằng bảng tần số

(table) và tỷ lệ phần trăm (prop.table). Thứ hai, sử dụng biểu đồ hộp (boxplot) để so sánh phân phối của các biến số định lượng quan trọng (gồm *age*, *chol*, *trestbps*, *thalach*, *oldpeak*) giữa hai nhóm "Normal" và "Risk Present". Lệnh `par(mfrow = c(2,3))` được dùng để hiển thị 6 biểu đồ trên cùng một lưới, với màu xanh lá cho nhóm bình thường và màu đỏ cho nhóm có nguy cơ.

```
# Cân bằng target  
table(df$target)
```

```
##  
##      Normal Risk present  
##      165      140
```


```
prop.table(table(df$target))
```

```
##  
##      Normal Risk present  
##  0.5409836  0.4590164
```

Kết quả cho thấy trong tổng số 305 quan sát, có 165 người thuộc nhóm bình thường ("Normal") và 140 người thuộc nhóm có nguy cơ mắc bệnh tim ("Risk Present"). Tỷ lệ tương ứng là 54.1% và 45.9%. Như vậy, tỷ lệ giữa hai lớp là xấp xỉ 1,18:1 (Normal : Risk present). Đây được coi là một tập dữ liệu tương đối cân bằng, không quá chênh lệch giữa hai lớp mục tiêu. Điều này rất thuận lợi cho việc xây dựng các mô hình Machine Learning, vì không cần phải áp dụng các kỹ thuật xử lý mất cân bằng dữ liệu một cách phức tạp. Các chỉ số đánh giá như Accuracy, Precision, Sensitivity và F1-score sẽ phản ánh khách quan hơn hiệu suất thực sự của mô hình.

Quan hệ giữa các biến số với target qua boxplot

```
# Boxplot so sánh
par(mfrow = c(2,3))
for(col in c("age", "chol", "trestbps", "thalach", "oldpeak", "ca")) {
  boxplot(df[[col]] ~ df$target, main = col, col = c("green", "red"))
}
```



Từ các biểu đồ hộp (boxplot) so sánh giá trị của từng biến định lượng giữa hai nhóm bệnh nhân có nguy cơ (Risk present) và không có nguy cơ (Normal):

age (tuổi): Nhóm bệnh nhân có nguy cơ mắc bệnh tim có độ tuổi trung vị cao hơn so với nhóm không có nguy cơ. Khoảng tứ phân vị của nhóm Risk present cũng dịch chuyển lên phía trên, cho thấy tuổi cao là một yếu tố nguy cơ quan trọng. Cả hai nhóm đều có một số giá trị ngoại lai ở phía trên.

chol (cholesterol): Nhóm Risk present có xu hướng có giá trị cholesterol cao hơn nhóm Normal, thể hiện qua đường trung vị cao hơn. Tuy nhiên, cả hai nhóm đều xuất hiện các giá trị ngoại lai rất cao, đặc biệt ở nhóm Normal. Điều này cho thấy cholesterol cao không phải là yếu tố duy nhất quyết định nguy cơ.

trestbps (huyết áp tâm thu khi nghỉ): Nhóm Risk present có huyết áp trung vị cao hơn nhóm Normal một chút, nhưng sự chênh lệch không quá rõ rệt. Cả hai nhóm đều có một số giá trị ngoại lai ở phía cao (trên 180 mmHg), tập trung nhiều hơn ở nhóm có nguy cơ.

thalach (nhịp tim tối đa đạt được): Ngược lại với các biến trên, nhóm Normal có nhịp tim trung vị cao hơn rõ rệt so với nhóm Risk present. Điều này cho thấy những người có thể đạt nhịp tim cao khi gắng sức thường có nguy cơ bệnh tim thấp hơn - một dấu hiệu tốt về sức khỏe tim mạch.

oldpeak (độ chênh ST): Nhóm Risk present có giá trị *oldpeak* trung vị cao hơn đáng kể so với nhóm Normal, và khoảng tứ phân vị cũng nằm ở mức cao hơn. Điều này phản ánh rằng độ chênh ST càng lớn thì nguy cơ bệnh tim càng cao. Nhóm Normal có phần lớn giá trị tập trung ở mức thấp (gần 0).

ca (số lượng mạch máu chính bị hẹp): Nhóm Risk present có giá trị *ca* trung vị cao hơn rõ rệt (khoảng 1) so với nhóm Normal (trung vị = 0). Hầu hết bệnh nhân trong nhóm Normal có *ca* = 0, trong khi nhóm Risk present có sự phân bố rộng hơn từ 0 đến 3. Đây là một yếu tố phân biệt rất mạnh giữa hai nhóm.

Các biến *age*, *chol*, *trestbps*, *oldpeak* và *ca* có xu hướng cao hơn ở nhóm có nguy cơ bệnh tim, trong khi *thalach* (nhịp tim tối đa) cao hơn ở nhóm không có nguy cơ. Những khác biệt này cho thấy các biến số đều có giá trị phân biệt tốt, đặc biệt là *thalach*, *oldpeak* và *ca*. Tuy nhiên, vẫn tồn tại một số giá trị ngoại lai cần được xử lý để tránh ảnh hưởng đến hiệu suất mô hình.

3.4. Tiền xử lý dữ liệu

3.4.1. Xử lý dữ liệu thiếu

Sau khi kiểm tra, bộ dữ liệu xuất hiện một số giá trị thiếu tại các thuộc tính khác nhau. Tiến hành loại bỏ các bản ghi chứa dữ liệu thiếu nhằm đảm bảo tính đầy đủ của dữ liệu trước khi thực hiện các bước tiền xử lý tiếp theo.

[1] 2

```
##      age      sex      cp trestbps      chol      fbs  restecg  thalach
##      0        0        0        0        1        0        0        0
##      exang  oldpeak    slope      ca      thal    target
##      0        1        0        0        0        0
```

Trong đoạn mã trên, hàm `sum(is.na(heart))` giúp xác định tổng số giá trị thiếu trong bộ dữ liệu, trong khi `colSums(is.na(heart))` giúp xác định số lượng giá trị thiếu trên từng thuộc tính. Sau khi xác định được các giá trị thiếu, nhóm sử dụng hàm `na.omit()` để loại bỏ toàn bộ các dòng chứa ít nhất một giá trị thiếu.

```
heart <- na.omit(heart)
```

```
##      age      sex      cp trestbps      chol      fbs  restecg  thalach
##      0        0        0        0        0        0        0        0
##      exang  oldpeak    slope      ca      thal    target
##      0        0        0        0        0        0
```

Kết quả kiểm tra sau xử lý cho thấy số lượng giá trị thiếu trong bộ dữ liệu bằng 0, chứng tỏ các bản ghi chứa dữ liệu khuyết đã được loại bỏ hoàn toàn.

3.4.2. Xử lý dữ liệu trùng lặp

Dữ liệu trùng lặp là các bản ghi có nội dung giống nhau xuất hiện nhiều hơn một lần trong bộ dữ liệu. Để xử lý dữ liệu trùng lặp, sử dụng hàm `duplicated()`. Hàm này trả về giá trị TRUE đối với những dòng bị lặp lại và FALSE đối với những dòng xuất hiện lần đầu tiên.

```
sum(duplicated(heart))
```

Kết quả ban đầu:

```
## [1] 3
```

```
heart <- heart[!duplicated(heart), ]
sum(duplicated(heart))
```

Kết quả sau khi xử lý:


```
## [1] 0
```

Lệnh `duplicated(heart)` được sử dụng để xác định các bản ghi bị trùng. Dấu ! có ý nghĩa phủ định, tức là chỉ giữ lại những dòng không bị trùng lặp. Sau đó, dữ liệu đã được cập nhật lại vào biến `heart`.

Sau khi xử lý, kết quả kiểm tra cho thấy bộ dữ liệu không còn bản ghi trùng lặp. Việc loại bỏ các dòng lặp giúp đảm bảo mỗi quan sát chỉ xuất hiện một lần, làm cho dữ liệu nhất quán hơn và hạn chế sai lệch trong quá trình huấn luyện mô hình Machine Learning.

3.4.3. Xử lý ngoại lệ

Để đảm bảo chất lượng dữ liệu đầu vào, tiến hành kiểm tra các giá trị bất thường trên các thuộc tính số gồm *age*, *trestbps*, *chol*, *thalach*, *oldpeak* và *ca*. Quá trình này được thực hiện thông qua thống kê mô tả kết hợp với biểu đồ hộp nhằm đánh giá phạm vi và sự phân bố của dữ liệu trước khi tiến hành xử lý.




Kết quả trước xử lý cho thấy bộ dữ liệu xuất hiện một số giá trị bất thường cực đoan, cụ thể là các giá trị có độ lệch rất lớn so với phạm vi hợp lý của dữ liệu, chẳng hạn như huyết áp nghỉ (*trestbps*) hoặc cholesterol (*chol*) quá cao, và nhịp tim tối đa (*thalach*) có giá trị âm. Đây là các giá trị không phù hợp về mặt dữ liệu nên cần được loại bỏ trước khi xây dựng mô hình.

```
# Xóa các dòng chứa outlier
heart <- heart[
  heart$trestbps < 300 &
  heart$chol < 700 &
  heart$thalach > 0,
]
# Kiểm tra thống kê mô tả sau xử lý
summary(heart[, num_cols])
```

Các điều kiện lọc để loại bỏ trực tiếp các bản ghi chứa giá trị bất thường cực đoan.

Boxplot các thuộc tính số sau xử lý



Sau khi xử lý, sử dụng summary() và boxplot() để kiểm tra lại dữ liệu. Kết quả cho thấy các giá trị bất thường cực đoan đã được loại bỏ. Một số điểm vẫn xuất hiện trên biểu đồ hộp, đặc biệt ở thuộc tính chol và trestbps, nhưng đây là các giá trị vẫn có thể xảy ra trong thực tế chứ không phải lỗi dữ liệu. Vì vậy, chỉ loại bỏ các giá trị bất thường cực đoan và giữ lại các giá trị biên hợp lý nhằm đảm bảo dữ liệu phản ánh đúng đặc điểm bệnh nhân và tránh làm mất thông tin quan trọng cho quá trình xây dựng mô hình Machine Learning.

3.4.4. Mã hóa biến phân loại

Sau khi hoàn thành các bước làm sạch dữ liệu, tiến hành mã hóa các thuộc tính phân loại nhằm chuyển đổi dữ liệu từ dạng văn bản sang dạng số. Việc mã hóa giúp dữ liệu phù hợp với yêu cầu đầu vào của các thuật toán Machine Learning.

```

# Mã hóa giới tính
heart$sex <- ifelse(heart$sex == "Male", 1, 0)

# Mã hóa Loại đau ngực
heart$cp <- factor(
  heart$cp,
  levels = c("Typical angina", "Atypical angina", "Non-anginal pain", "Asymptomatic"),
  labels = c(0, 1, 2, 3)
)
heart$cp <- as.numeric(as.character(heart$cp))

# Mã hóa đường huyết lúc đói
heart$fbs <- ifelse(heart$fbs == TRUE, 1, 0)

# Mã hóa điện tâm đồ lúc nghỉ
heart$restecg <- factor(
  heart$restecg,
  levels = c("Normal", "ST-T abnormality", "Left ventricular hypertrophy"),
  labels = c(0, 1, 2)
)
heart$restecg <- as.numeric(as.character(heart$restecg))

# Mã hóa đau thắt ngực do gắng sức
heart$exang <- ifelse(heart$exang == "Yes", 1, 0)

# Mã hóa độ dốc đoạn ST
heart$slope <- factor(
  heart$slope,
  levels = c("Upsloping", "Flat", "Downsloping"),
  labels = c(1, 2, 3)
)
heart$slope <- as.numeric(as.character(heart$slope))

# Mã hóa Thal
heart$thal <- factor(
  heart$thal,
  levels = c("Normal", "Fixed defect", "Reversable defect"),
  labels = c(0, 1, 2)
)
heart$thal <- as.numeric(as.character(heart$thal))

# Mã hóa biến mục tiêu
heart$target <- ifelse(heart$target == "Risk present", 1, 0)

```

Trong đoạn mã trên, sử dụng hàm *ifelse()* để mã hóa các biến chỉ có hai giá trị như *sex*, *fbs*, *exang* và *target*. Các thuộc tính này được chuyển thành dạng nhị phân với giá trị 1 hoặc 0 tương ứng với từng nhóm dữ liệu.

Đối với các thuộc tính có nhiều hơn hai mức giá trị như *cp*, *restecg*, *slope* và *thal*, nhóm sử dụng hàm *factor()* để xác định thứ tự các mức dữ liệu và gán mã số tương ứng cho từng nhóm. Sau đó, dữ liệu được chuyển sang kiểu số bằng hàm *as.numeric()* để phục vụ cho quá trình huấn luyện mô hình.

```
## 'data.frame': 297 obs. of 14 variables:
## $ age : int 69 69 66 65 64 64 63 61 60 59 ...
## $ sex : num 1 0 0 1 1 1 1 0 1 ...
## $ cp : num 0 0 0 0 0 0 0 0 0 ...
## $ trestbps: int 160 140 150 138 110 170 145 134 150 178 ...
## $ chol : int 234 239 226 282 211 227 233 234 240 270 ...
## $ fbs : num 1 0 0 1 0 0 1 0 0 0 ...
## $ restecg : num 2 0 0 2 2 2 2 0 0 2 ...
## $ thalach : int 131 151 114 174 144 155 150 145 171 145 ...
## $ exang : num 0 0 0 0 1 0 0 0 0 0 ...
## $ oldpeak : num 0.1 1.8 2.6 1.4 1.8 0.6 2.3 2.6 0.9 4.2 ...
## $ slope : num 2 1 3 2 2 2 3 2 1 3 ...
## $ ca : int 1 2 0 1 0 0 0 2 0 0 ...
## $ thal : num 0 0 0 0 0 2 1 0 0 2 ...
## $ target : num 0 0 0 1 0 0 0 1 0 0 ...
## - attr(*, "na.action")= 'omit' Named int [1:2] 191 239
## .. attr(*, "names")= chr [1:2] "191" "239"
```

Sau khi hoàn thành quá trình mã hóa, sử dụng hàm *str()* để kiểm tra lại cấu trúc dữ liệu. Kết quả cho thấy các thuộc tính phân loại đã được chuyển đổi thành dạng số và sẵn sàng cho quá trình xây dựng mô hình Machine Learning.

3.4.5. Chuẩn hóa dữ liệu

Trước khi xây dựng mô hình Machine Learning, việc chuẩn hóa giúp hạn chế sự chênh lệch quá lớn giữa các thuộc tính và đảm bảo các biến có mức độ ảnh hưởng cân bằng hơn trong quá trình huấn luyện mô hình. Phương pháp StandardScaler thông qua hàm *scale()* giúp đưa dữ liệu về dạng có giá trị trung bình bằng 0 và độ lệch chuẩn bằng 1.

```
# Chọn các thuộc tính số cần chuẩn hóa
scale_cols <- c("age",
               "trestbps",
               "chol",
               "thalach",
               "oldpeak",
               "ca")

# Chuẩn hóa dữ liệu
heart[scale_cols] <- scale(heart[scale_cols])
```

Trong đoạn mã trên, nhóm sử dụng hàm *scale()* để chuẩn hóa các thuộc tính số gồm age, trestbps, chol, thalach, oldpeak và ca về cùng một thang đo. Kết quả kiểm tra bằng hàm *summary()* cho thấy các thuộc tính đã được chuẩn hóa thành công với giá trị trung bình xấp xỉ bằng 0; các giá trị âm hoặc dương xuất hiện là hoàn toàn bình thường do dữ liệu được biểu diễn tương đối so với giá trị trung bình.

Trước khi chuẩn hóa:


```
##      age      chol      thalach
## Min.   :29.00   Min.   :126.0   Min.    : 71.0
## 1st Qu.:48.00   1st Qu.:211.0   1st Qu.:133.0
## Median :56.00   Median :243.0   Median :153.0
## Mean   :54.54   Mean   :247.4   Mean    :149.6
## 3rd Qu.:61.00   3rd Qu.:276.0   3rd Qu.:166.0
## Max.   :77.00   Max.   :564.0   Max.    :202.0
```

Sau khi chuẩn hóa:

```
##      age      chol      thalach
## Min.   :-2.8224   Min.   :-2.33377   Min.    :-3.4261
## 1st Qu.: -0.7229   1st Qu.: -0.69907   1st Qu.: -0.7235
## Median : 0.1611   Median : -0.08366   Median : 0.1482
## Mean   : 0.0000   Mean   : 0.00000   Mean    : 0.0000
## 3rd Qu.: 0.7136   3rd Qu.: 0.55098   3rd Qu.: 0.7149
## Max.   : 2.4816   Max.    : 6.08970   Max.    : 2.2841
```

Kết quả chuẩn hóa giúp giảm ảnh hưởng của sự khác biệt về đơn vị đo giữa các thuộc tính và tạo điều kiện thuận lợi cho quá trình huấn luyện các mô hình Machine Learning, đặc biệt là các thuật toán nhạy cảm với thang đo dữ liệu như KNN, SVM và Logistic Regression.

CHƯƠNG 4. TRỰC QUAN HÓA DỮ LIỆU (DATA VISUALIZATION)

4.1. Phân bố dữ liệu


4.1.1. Phân bố biến mục tiêu

Biến mục tiêu (Target) là biến nhị phân (binary variable) với hai giá trị chính là 0 và 1 biểu thị tình trạng mắc bệnh tim của bệnh nhân. Biến mục tiêu là biến nhị phân gồm 2 giá trị: 0 (không mắc bệnh tim) và 1 (mắc bệnh tim).

```
#-----  
# PHÂN BỐ BIẾN MỤC TIÊU  
#-----  
data %>%  
  count(target)%>%  
  mutate(percent = n / sum(n) * 100)
```

```
##   target    n percent  
## 1      0 160 53.87205  
## 2      1 137 46.12795
```

Kết quả dữ liệu thống kê cho thấy rằng tập dữ liệu bao gồm có 297 quan sát, trong đó có 160 người không mắc bệnh tim (53.87%) và 137 người mắc bệnh tim (46.13%). Tỷ lệ của tập dữ liệu khá cân bằng, sự chênh lệch giữa hai nhóm chỉ khoảng 23 trường hợp, tương đương với 7.74% tổng số mẫu nghiên cứu.



Thông qua biểu đồ cho thấy số lượng bệnh nhân thuộc nhóm không mắc bệnh tim cao hơn nhóm có mắc bệnh tim. Nhóm không mắc bệnh tim chiếm tỉ lệ cao với 53.87%. Dữ liệu có sự phân bố tương đối cân bằng giữa cả hai lớp và không xuất hiện hiện tượng


cho thấy mất cân bằng nghiêm trọng trong tập dữ liệu. Từ đó có thể tạo được điều kiện thuận lợi cho các bước phân tích thống kê và xây dựng mô hình học máy.

4.1.2. Phân bố các biến định lượng

Các biến định lượng trong tập dữ liệu gồm: Số tuổi của bệnh nhân (age), huyết áp lúc nghỉ ngơi (trestbps) được đo theo đơn vị mmHg, nồng độ cholesterol toàn phần trong máu (chol) được đo bằng đơn vị mg/dL, nhịp tim tối đa đạt được trong quá trình kiểm tra hoặc vận động (thalach), chỉ số phản ánh mức độ ảnh hưởng của hoạt động gắng sức lên tim (oldpeak).

Phân bố biến age

Age là biến biểu thị độ tuổi của đối tượng nghiên cứu, được tính theo đơn vị năm, là một trong những yếu tố quan trọng trong đánh giá nguy cơ mắc bệnh tim mạch, vì nguy cơ xuất hiện các bệnh lý tim thường có xu hướng tăng theo tuổi.



Biểu đồ cho thấy rằng độ tuổi của các bệnh nhân trong tập dữ liệu trải dài từ khoảng 29 đến 77 tuổi, phần lớn tập trung trong khoảng từ 45 -65 tuổi.


Xu hướng dịch chuyển của biểu đồ từ vùng trung tâm về hai bên cánh, dữ liệu giảm dần. Phía bên trái là nhóm đối tượng trẻ tuổi, độ cao của các cột hạ thấp dần từ mức sắp xỉ 50 tuổi xuống 40 tuổi và giảm sâu hẳn từ ngưỡng 35 tuổi trở xuống, phía ngoài cùng chỉ

ghi nhận số ít người trẻ mắc bệnh tim. Phía bên phải, đại diện cho nhóm đối tượng từ trung niên đến lớn tuổi, xu hướng biểu đồ sụt giảm cũng diễn ra khi chạm ngưỡng trên 60 tuổi và ở mức thấp ở khoảng độ trên 70 và kết thúc thấp nhất ở vùng cận 80 tuổi. Sự giảm dần đối xứng này diễn ra ở cả hai đầu mút của biểu đồ và không bị lệch về phía nào cụ thể, không bị kéo đuôi dài ở phía bên phải hay bên trái bất thường.

Về mặt y học, từ sau 50 tuổi, cơ thể bắt đầu lão hóa rõ rệt, khả năng tự phục hồi suy giảm và các yếu tố nguy cơ tích lũy theo thời gian dần biểu hiện thành bệnh. Vì vậy, số ca mắc bệnh thường tập trung nhiều nhất ở nhóm tuổi này.

Phân bố biến $trestbps$

Biến $Trestbps$ là biến biểu thị huyết áp tâm thu khi nghỉ ngơi của đối tượng nghiên cứu, thường được đo bằng đơn vị mmHg. Huyết áp là một chỉ số quan trọng trong đánh giá sức khỏe tim mạch, bởi tình trạng tăng huyết áp có thể làm tăng nguy cơ mắc các bệnh tim mạch, đột quỵ và các biến chứng liên quan đến hệ tuần hoàn.




Biểu đồ phân bố huyết áp lúc nghỉ cho thấy chỉ số của các bệnh nhân trong tập dữ liệu dao động rộng, trong khoảng từ 90 đến gần 210 mmHg.

Theo tiêu chuẩn y tế của Hiệp hội Tim mạch Hoa Kỳ (AHA), huyết áp tâm thu được phân loại như sau: dưới 120 mmHg là bình thường, từ 120–129 mmHg là tăng huyết áp nhẹ (Elevated), từ 130–139 mmHg là Tăng huyết áp Giai đoạn 1 (Stage 1), từ 140 mmHg trở

lên là Tăng huyết áp Giai đoạn 2 (Stage 2), và trên 180 mmHg là Khủng hoảng tăng huyết áp (Hypertensive Crisis). Đối chiếu với biểu đồ, phần lớn bệnh nhân trong tập dữ liệu thuộc nhóm từ huyết áp bình thường đến tăng huyết áp giai đoạn 1 (110–140 mmHg). Đặc điểm này hoàn toàn phù hợp với thực tế dịch tễ của các tập dữ liệu nền về bệnh tim mạch — nơi phần lớn quần thể nghiên cứu nằm ở ngưỡng cảnh báo hoặc tiền bệnh lý chứ không nhất thiết phải ở mức nguy hiểm tính mạng ngay lập tức. Dù vậy, một tỷ lệ không nhỏ bệnh nhân vẫn có huyết áp cao thuộc Giai đoạn 2 (140–180 mmHg), đặt ra nhóm đối tượng có nguy cơ tim mạch cao đáng được quan tâm trong các mô hình dự báo

Phân bố biến chol

Chol là biến phản ánh nồng độ cholesterol toàn phần trong máu. Cholesterol là một loại chất béo cần thiết cho cơ thể, tuy nhiên mức cholesterol quá cao có thể làm tăng nguy cơ xơ vữa động mạch, hẹp mạch vành và các bệnh lý tim mạch khác.



Biểu đồ cho thấy nồng độ cholesterol toàn phần trong máu của các bệnh nhân dao động từ 120 đến 560 mg/dL. Phần đuôi đồ thị xuất hiện một cột ngoại lai nhỏ biệt lập ở dải 550–600 mg/dL, khiến phân bố của biến Chol có xu hướng lệch phải rõ rệt.


Theo khuyến cáo của Hiệp hội Tim mạch Hoa Kỳ (AHA) và Chương trình Giáo dục Cholesterol Quốc gia (NCEP), nồng độ cholesterol toàn phần dưới 200 mg/dL là mức mong muốn (Desirable), từ 200–239 mg/dL là mức ranh giới cao (Borderline High), và từ 240 mg/dL trở lên là mức cao (High). Đối chiếu với biểu đồ, phần lớn bệnh nhân trong tập dữ

liệu nằm trong vùng từ ranh giới đến mức cao (200–300 mg/dL), trong khi tỷ lệ người đạt mức lý tưởng là rất thấp.

Đặc biệt, nhóm bệnh nhân ở phần đuôi lệch phải (trên 400 mg/dL) tuy chiếm số lượng nhỏ nhưng đại diện cho các trường hợp rối loạn lipid máu nghiêm trọng, có thể liên quan đến hội chứng tăng cholesterol máu gia đình (Familial Hypercholesterolemia). Những cá nhân này đối mặt với nguy cơ cực kỳ cao bị xơ vữa động mạch sớm, nhồi máu cơ tim hoặc tai biến mạch máu não ngay khi còn trẻ. Việc nhận diện cả nhóm nguy cơ phổ biến (vùng đỉnh) lẫn các ca bệnh đặc biệt ở vùng đuôi đồ thị sẽ giúp các nhà nghiên cứu đưa ra chiến lược sàng lọc và can thiệp y tế bằng thuốc phù hợp.

Phân bố biến thalach

Thalach là biến phản ánh nhịp tim tối đa đạt được của đối tượng trong quá trình vận động hoặc kiểm tra gắng sức. Chỉ số này thể hiện khả năng đáp ứng của hệ tim mạch khi cơ thể hoạt động. Người có khả năng đạt nhịp tim tối đa cao hơn thường có chức năng tim mạch tốt hơn, trong khi giá trị thấp có thể liên quan đến khả năng gắng sức bị hạn chế hoặc các vấn đề về tim mạch




Phân bố dữ liệu có xu hướng lệch trái nhẹ, thể hiện qua việc đuôi phân bố kéo dài về phía các giá trị thấp hơn. Điều này cho thấy phần lớn bệnh nhân đạt được nhịp tim tối đa ở mức tương đối cao, trong khi chỉ có một số ít bệnh nhân đạt mức nhịp tim tối đa thấp.

Không quan sát thấy các giá trị ngoại lệ quá cực đoan và dữ liệu vẫn duy trì dạng phân bố tương đối gần chuẩn

Trong y học, nhịp tim tối đa lý thuyết thường được ước tính theo công thức $220 - \text{tuổi}$ (nhịp/phút). Do tập dữ liệu này có phần lớn bệnh nhân ở độ tuổi 50–65, nhịp tim tối đa theo lý thuyết của nhóm tuổi này sẽ nằm trong khoảng 155–170 nhịp/phút là hoàn toàn nhất quán với đỉnh phân phối quan sát được trong biểu đồ tại 155–165 nhịp/phút, cho thấy dữ liệu có tính nhất quán sinh lý tốt. Tuy nhiên, các bệnh nhân chỉ đạt nhịp tim tối đa dưới 120 bpm dù đang gắng sức là dấu hiệu đáng lo ngại về mặt lâm sàng — điều này có thể phản ánh chức năng tim suy yếu, đang dùng thuốc chẹn beta (beta-blockers) làm hạn chế nhịp tim, hoặc không thể hoàn thành bài kiểm tra gắng sức do đau ngực hoặc khó thở. Ngược lại, nhóm đạt nhịp tim trên 195 nhịp/phút là rất ít và có thể đại diện cho những bệnh nhân trẻ hơn hoặc có thể lực đặc biệt tốt. Đây là một trong những biến dự đoán có giá trị cao nhất do mối liên hệ sinh lý trực tiếp giữa khả năng đáp ứng nhịp tim khi gắng sức và tình trạng bệnh tim mạch.

Phân bố biến oldpeak

Oldpeak là biến biểu thị mức độ giảm của đoạn ST trên điện tâm đồ (ECG) khi gắng sức so với lúc nghỉ ngơi. Giá trị càng cao thường cho thấy tim chịu áp lực lớn hơn khi vận động và có thể liên quan đến nguy cơ mắc bệnh tim mạch.



Biểu đồ thấy biến Oldpeak có giá trị dao động từ khoảng 0 đến hơn 6. Ước lượng biểu đồ được phân bố khoảng 0-0.5 chiếm xấp xỉ 40% tập dữ liệu, khoảng 120 quan sát và giảm mạnh theo hình bậc thang trước khi kéo dài thành một dải đuôi mỏng đến tận mốc 6-6.5.

Biểu đồ có dạng lệch phải rõ rệt khi tần suất xuất hiện cao ở các giá trị nhỏ và giảm dần khi giá trị Oldpeak tăng lên. Đuôi phân bố kéo dài về phía các giá trị lớn hơn, cho thấy chỉ có một số ít bệnh nhân có chỉ số Oldpeak cao.

Từ góc độ y học, phân phối này hoàn toàn có ý nghĩa sinh lý và lâm sàng rõ ràng. Giá trị Oldpeak = 0 có nghĩa là không có sự thay đổi đoạn ST nào khi gắng sức so với lúc nghỉ — đây là trạng thái bình thường hoặc lý tưởng của tim khỏe mạnh. Việc phần lớn bệnh nhân có Oldpeak gần bằng 0 (khoảng 120 trong tổng số 297 quan sát, tức xấp xỉ 40%) cho thấy một tỷ lệ đáng kể trong mẫu có chức năng tim còn tương đối ổn định ngay cả khi gắng sức. Tuy nhiên, đây cũng là tập dữ liệu bệnh tim, nên sự hiện diện của các giá trị Oldpeak cao từ 2 đến 6 phản ánh nhóm bệnh nhân có thiếu máu cơ tim (myocardial ischemia) nghiêm trọng — tim không được cung cấp đủ máu khi hoạt động gắng sức, dẫn đến biến đổi sóng điện tim rõ rệt.

4.1.3. Phân bố các biến định tính


Các biến định tính trong tập dữ liệu gồm: Giới tính (sex), Loại đau ngực (cp), Chỉ số đường huyết lúc đói (fbs), kết quả điện tâm đồ khi bệnh nhân ở trạng thái nghỉ (restecg), cho biết bệnh nhân có bị đau thắt ngực trong quá trình cận động khi gắng sức hay không (exang), mô tả độ dốc của điện tâm đồ trong quá trình gắng sức (slope), Số mạch máu lớn được nhuộm màu bằng phương pháp huỳnh quang (ca), kết quả xét nghiệm tưới máu cơ tim bằng Thallium (thal) và biến mục tiêu target đã được phân tích.

Phân bố biến sex

Sex là biến thể hiện giới tính của những người trong tập dữ liệu nghiên cứu. Phân bố của biến sex gồm một biến nhị phân với hai giá trị 0 (nữ) và 1 (Nam)

```
data %>%
  count(sex) %>%
  mutate(percent = n / sum(n) * 100)
```

```
##   sex    n percent
## 1    0    96 32.32323
## 2    1   201 67.67677
```


Qua biểu đồ có thể quan sát được trong tập dữ liệu có sự mất cân bằng rõ rệt với tỷ lệ nam gấp đôi nữ. Tỷ lệ nam so với nữ trong tập dữ liệu này là 2:1, nghĩa là cứ 2 bệnh nhân nam thì chỉ có 1 bệnh nhân nữ. Điều này không phải là ngẫu nhiên mà phản ánh thực tế lâm sàng được ghi nhận rộng rãi trong y văn: bệnh tim mạch vành có xu hướng xuất hiện phổ biến hơn ở nam giới, đặc biệt trong nhóm tuổi trung niên (50–65 tuổi) — đúng với đặc điểm độ tuổi của tập dữ liệu này. Nguyên nhân sinh lý được giải thích là do hormone estrogen ở nữ giới có tác dụng bảo vệ tim mạch trong giai đoạn tiền mãn kinh, khiến phụ nữ thường phát bệnh tim mạch muộn hơn nam giới khoảng 10 năm .

Phân bố biến cp

cp là biến mô tả loại đau ngực mà bệnh nhân gặp phải, phản ánh các biểu hiện lâm sàng liên quan đến bệnh lý tim mạch được phân thành từng mức phân loại. Được phân thành 4 nhóm: Biến 0 (Đau thắt ngực điển hình), 1 (Đau thắt ngực không điển hình), 2 (Đau ngực không do thiếu máu cơ tim), 3 (Không có triệu chứng đau ngực).

```
data %>%
  count(cp) %>%
  mutate(percent = n / sum(n) * 100)
```

```
##   cp    n percent
## 1  0    23  7.744108
## 2  1    49 16.498316
## 3  2    83 27.946128
## 4  3   142 47.811448
```



Biểu đồ có xu hướng tăng dần đều từ trái sang phải - các cột tăng theo thứ tự từ $cp = 0$ (xấp xỉ 25) đến $cp = 3$ (xấp xỉ 137). Xu hướng này rất đáng chú ý vì nó nghịch lý với trực giác thông thường: nhóm có triệu chứng rõ ràng nhất ($cp = 0$, đau thắt ngực điển hình) lại chiếm tỷ lệ nhỏ nhất, trong khi nhóm không có triệu chứng ($cp = 3$, Asymptomatic) lại chiếm tỷ lệ lớn nhất.


Việc nhóm Asymptomatic ($cp = 3$) chiếm gần một nửa tập dữ liệu phản ánh một thực tế y học quan trọng được gọi là "Silent Heart Disease" (Bệnh tim thầm lặng) — rất nhiều bệnh nhân có bệnh tim mạch vành nhưng không biểu hiện triệu chứng đau ngực rõ ràng. Đây cũng là lý do tại sao bệnh tim thường bị bỏ sót trong chẩn đoán lâm sàng thông thường nếu chỉ dựa vào triệu chứng đau ngực. Trong bối cảnh tập dữ liệu này, nhiều bệnh nhân $cp = 3$ vẫn được phát hiện có bệnh tim qua các xét nghiệm cận lâm sàng như ECG và stress test, chứ không phải qua triệu chứng đau ngực.

Phân bố biến fbs

Biến `fbs` là biến nhị phân được mã hóa thành 2 giá trị 0 (đường huyết lúc đói ≤ 120 mg/dL - bình thường) và 1 (đường huyết lúc đói > 120 mg/dL — có thể là dấu hiệu của tiểu đường hoặc tiền tiểu đường)

```
data %>%
  count(fbs) %>%
  mutate(percent = n / sum(n) * 100)
```

```
##   fbs   n percent
## 1    0 254 85.52189
## 2    1  43 14.47811
```



Quan sát biểu đồ cho thấy cột $fbs = 0$ vượt trội hơn hẳn so với cột $fbs = 1$. Tỷ lệ chênh lệch giữa hai nhóm lên đến xấp xỉ 6: 1 thì đây là mức mất cân bằng rất lớn so với tất cả các biến phân loại đã phân tích trước đó. Với tỷ lệ 85.52% so với 14.47%. Đây là mức mất cân bằng nghiêm trọng nhất trong tất cả các biến phân loại nhị phân đã phân tích trong tập dữ liệu này.


Trong dân số chung, tỷ lệ người có đường huyết lúc đói cao hơn 120 mg/dL (tương đương ngưỡng chẩn đoán đái tháo đường hoặc tiền đái tháo đường nặng) thường chiếm khoảng 10–15%, đúng với con số 14.47% quan sát được trong tập dữ liệu này. Đường huyết lúc đói > 120 mg/dL là dấu hiệu của rối loạn chuyển hóa glucose — có thể là tiền đái tháo đường (Pre-diabetes) hoặc đái tháo đường type 2 (T2DM). Mối liên hệ giữa đái tháo đường và bệnh tim mạch là được ghi nhận rõ ràng trong y văn — bệnh nhân đái tháo đường có nguy cơ mắc bệnh tim mạch vành cao gấp 2–4 lần so với người không mắc, do đường huyết cao gây tổn thương thành mạch máu, thúc đẩy quá trình xơ vữa động mạch. Phân phối này phản ánh đúng tỷ lệ dịch tễ học của rối loạn đường huyết trong dân số chung

Phân bố biến restecg

Biến restecg là biến phân loại danh nghĩa với 3 mức: 0 (bình thường), 1 (tình trạng có bất thường trên sóng ST hoặc sóng T của điện tâm đồ), và 2 (tình trạng phì đại thất trái)

```
data %>%
  count(restecg) %>%
  mutate(percent = n / sum(n) * 100)
```

	restecg	n	percent
## 1	0	147	49.494949
## 2	1	4	1.346881
## 3	2	146	49.158249



Biểu đồ phân phối có hình dạng chữ U rất rõ ràng - hai cột ở hai đầu có chiều cao sắp xỉ gần bằng nhau, trong khi cột ở giữa cực kỳ thấp với 4 quan sát. Đây chính là kiểu phân phối hai đỉnh. Sự đối xứng gần như cân bằng giữa nhóm 0 và nhóm 2 là điều đặc biệt chú ý vì chúng gần như chia đôi tập dữ liệu với tỷ lệ thống kê cho ra xấp xỉ.


Việc 49.49% bệnh nhân có ECG bình thường trong khi vẫn được đưa vào tập dữ liệu nghiên cứu bệnh tim cho thấy rằng ECG lúc nghỉ không phải công cụ sàng lọc quá tốt - nhiều người có ECG bình thường vẫn có thể mắc bệnh tim tiềm ẩn chỉ phát hiện được qua stress test hoặc các xét nghiệm chuyên sâu hơn. 49.16% bệnh nhân thuộc nhóm 2 là con số rất cao, phản ánh thực tế rằng trong nhóm bệnh nhân được theo dõi nguy cơ tim mạch, phì đại thất trái do tăng huyết áp mãn tính là tình trạng cực kỳ phổ biến. Tuy nhiên nhóm 1 có tỷ lệ cực kỳ thấp mặc dù nếu xét về lý thuyết thì đây là dấu hiệu đặc trưng nhất của thiếu máu cơ tim cấp tính. Tuy thế có thể được giải thích bởi thực tế là bất thường sóng ST-T thường chỉ xuất hiện rõ ràng khi gắng sức (được đo bởi biến Oldpeak) chứ không phải lúc nghỉ ngơi, nên ít bệnh nhân biểu hiện bất thường này trên ECG nghỉ.

Phân bố biến exang

exang là biến nhị phân mang 2 giá trị: 0 (không xuất hiện đau thắt ngực khi vận động) và 1 (có xuất hiện đau thắt ngực khi vận động)

```
data %>%
  count(exang) %>%
  mutate(percent = n / sum(n) * 100)
```

```
##   exang   n percent
## 1     0 200  67.34007
## 2     1  97  32.65993
```



Biểu đồ cho thấy cột $\text{exang} = 0$ cao gấp khoảng 2 lần cột $\text{exang} = 1$. Mức độ mất cân bằng này nằm ở mức chấp nhận được trong học máy. Đáng chú ý là tỷ lệ phân chia này gần như giống hệt biến Sex về mặt con số, dù hai biến này hoàn toàn độc lập về nội dung - đây có thể là trùng hợp hoặc phản ánh mối tương quan tiềm ẩn giữa giới tính và nguy cơ đau thắt ngực khi gắng sức, tức là nam giới có xu hướng bị đau thắt ngực khi gắng sức nhiều hơn nữ giới do tỷ lệ bệnh mạch vành cao hơn.


Từ góc độ y học, biến exang mang ý nghĩa lâm sàng rất quan trọng và trực tiếp. Đau thắt ngực khi vận động là triệu chứng kinh điển và đặc trưng nhất của bệnh động mạch vành, xảy ra khi nhu cầu oxy của cơ tim tăng lên trong lúc gắng sức nhưng lòng mạch bị hẹp không cung cấp đủ máu. Đây cũng là lý do tại sao kiểm tra gắng sức được sử dụng rộng rãi trong chẩn đoán bệnh tim — khả năng xuất hiện đau thắt ngực khi tăng nhu cầu oxy là tiêu chí dương tính quan trọng của bài test này.

Phân bố biến slope

Slope là biến phân loại thứ tự với 3 mức độ: 1 (dốc lên - ít đáng lo ngại nhất), 2 (Phẳng ngang - trung gian về mức độ nguy hiểm), 3 (Dốc xuống - dạng nguy hiểm nhất)

```
data %>%
  count(slope) %>%
  mutate(percent = n / sum(n) * 100)
```

```
## slope n percent
## 1 139 46.801347
## 2 137 46.127946
## 3 21 7.070707
```



Biểu đồ có phân phối lệch phải với hai đỉnh gần bằng nhau ở mức xấp xỉ 139 và 137 quan sát, trong khi cột thứ ba thấp hơn rất nhiều chỉ gồm 21 quan sát.


Việc slope = 3 chỉ chiếm 7.07% với 21 quan sát — mặc dù đây là dạng nguy hiểm nhất về mặt lâm sàng — phản ánh thực tế rằng đây là dạng hiếm gặp hơn trong quần thể bệnh nhân, và khi xuất hiện thường đi kèm triệu chứng nghiêm trọng đến mức bệnh nhân thường được can thiệp sớm trước khi tiếp tục tham gia các nghiên cứu.

Phân bố biến ca

Biến ca thể hiện số lượng động mạch vành chính được quan sát thông qua kỹ thuật chụp huỳnh quang có sử dụng chất cản quang. Đây là biến phân loại thứ tự (Ordinal Variable) với 4 mức từ 0 đến 3: 0 (Không có động mạch nào bị tổn thương), 1 (Có 1 động mạch bị tổn thương), 2 (có 2 động mạch bị tổn thương), 3 (có 3 động mạch bị tổn thương)

```
data %>%
  count(ca) %>%
  mutate(percent = n / sum(n) * 100)
```

```
## ca n percent
## 1 0 174 58.585859
## 2 1 65 21.885522
## 3 2 38 12.794613
## 4 3 20 6.734007
```



Nhìn vào biểu đồ, phân phối có hình dạng giảm dần liên tục từ trái sang phải, với cột ca = 0 vượt trội hoàn toàn với gần 3/5 tổng mẫu, sau đó mỗi bước tăng thêm một động mạch tổn thương, số lượng quan sát gần như giảm đi một nửa: từ 174 xuống 65 (giảm 63%), từ 65 xuống 38 (giảm 42%), từ 38 xuống 20 (giảm 47%). Xu hướng giảm đều đặn này không phải ngẫu nhiên mà phản ánh quy luật dịch tễ học tự nhiên của bệnh mạch vành — càng nhiều nhánh động mạch bị tổn thương, bệnh càng nặng và càng hiếm gặp hơn trong quần thể.


Biểu đồ có phân phối lệch phải dạng bậc thang giảm dần, với 58.59% bệnh nhân không có tổn thương động mạch và tỷ lệ giảm đều đặn khi số nhánh tổn thương tăng lên, cho đến 6.73% bệnh nhân có cả 3 nhánh bị tổn thương. Đây là biến có giá trị chẩn đoán khách quan cao nhất trong toàn bộ tập dữ liệu vì được đo bằng kỹ thuật tiêu chuẩn vàng, và được dự đoán sẽ là một trong những biến có Feature Importance cao nhất trong mô hình phân loại bệnh tim

Phân bố biến thal

Biến thal là biến phản ánh kết quả xét nghiệm tưới máu cơ tim bằng Thallium, được sử dụng để đánh giá mức độ cung cấp máu cho cơ tim. Đây cũng là một biến phân loại thứ tự với 3 giá trị: 0 (bình thường), 1 (Khiếm khuyết cố định), 3 (Khiếm khuyết có thể hồi phục)

```
data %>%
  count(thal) %>%
  mutate(percent = n / sum(n) * 100)
```

```
##   thal   n percent
## 1    0 164 55.218855
## 2    1  18  6.060606
## 3    2 115 38.720539
```



Biểu đồ cho thấy phân phối có hình dạng chữ U không đối xứng. Biến thal = 0 chiếm 55.22% — nhóm này có kết quả xạ hình tim bình thường, tưới máu cơ tim đồng đều và đầy đủ cả khi nghỉ lẫn khi gắng sức, không phát hiện vùng thiếu máu. Đây là nhóm có chức năng tưới máu cơ tim tốt nhất và được kỳ vọng có tỷ lệ bệnh tim thấp hơn so với hai nhóm còn lại. Biến thal = 1 chỉ chiếm 6.06% với 18 quan sát — đây là trường hợp có vùng cơ tim không được tưới máu cả khi nghỉ lẫn khi gắng sức, thường là dấu hiệu của sẹo cơ tim sau nhồi máu cơ tim cũ, hoặc vùng cơ tim đã hoại tử và không còn khả năng hồi phục. Đây là kết quả nghiêm trọng vì cho thấy được tổn thương cơ tim đã xảy ra không thể phục hồi. Thal = 2 chiếm 38.72% với 115 quan sát. Đây là nhóm có vùng cơ tim thiếu máu khi gắng sức nhưng tưới máu bình thường khi nghỉ ngơi, tức tim nhận đủ máu lúc nghỉ nhưng không đủ khi tăng nhu cầu oxy tuy nhiên vùng tim này có thể cứu vãn được nếu được tái tưới máu kịp thời.

4.2. Phân tích tương quan giữa các biến

Ma trận tương quan sử dụng hệ số tương quan Pearson (r) chạy từ -1 đến 1. Trong đó:

- $r > 0$: Tương quan thuận
- $r < 0$: Tương quan nghịch
- r xấp xỉ 0: Không có mối quan hệ tuyến tính.

Dựa trên tập dữ liệu heart_cleveland_upload đã được làm sạch trước đó tiến hành xây dựng ma trận tương quan nhằm xác định mức độ tương quan giữa các biến trong tập dữ liệu. Kết quả được thể hiện thông qua ma trận tương quan và kiểm định ý nghĩa thống kê tương ứng.

Phân loại mức độ tương quan bằng cách lấy giá trị tuyệt đối của hệ số tương quan đi so sánh. Nếu nhỏ hơn 0.2 được phân vào tương quan rất yếu, lớn hơn 0.2 và nhỏ hơn 0.4 là yếu, lớn hơn 0.4 và nhỏ hơn 0.6 là trung bình, lớn hơn 0.6 và nhỏ hơn 0.8 là mạnh và nếu trên 0.8 là rất mạnh.

##	Variable	Correlation	Group	Direction
## thal	thal	0.521	Trung bình	Thuận
## ca	ca	0.463	Trung bình	Thuận
## oldpeak	oldpeak	0.424	Trung bình	Thuận
## exang	exang	0.421	Trung bình	Thuận
## cp	cp	0.409	Trung bình	Thuận
## slope	slope	0.333	Yếu	Thuận
## sex	sex	0.278	Yếu	Thuận
## age	age	0.227	Yếu	Thuận
## restecg	restecg	0.166	Rất yếu	Thuận
## trestbps	trestbps	0.153	Rất yếu	Thuận
## chol	chol	0.080	Rất yếu	Thuận
## fbs	fbs	0.003	Rất yếu	Thuận
## thalach	thalach	-0.424	Trung bình	Nghịch

Biến thal là biến có mức tương quan lớn nhất với biến mục tiêu. Từ đây cho thấy rằng kết quả xét nghiệm Thallium có liên quan đáng kể với khả năng mắc bệnh tim. Tiếp theo đó là biến ca phản ánh số lượng động mạch vành được quan sát qua huỳnh quang có mối liên hệ khá chặt chẽ với các tình trạng bệnh tim. Các biến như oldpeak, exang, cp cũng cho thấy được mức độ chênh xuống đoạn ST, tình trạng đau thắt ngực khi gắng sức và các loại đau ngực đều là những yếu tố có liên quan đến nguy cơ mắc bệnh tim.

Ngoài ra, các biến slope, sex, age cũng có tương quan thuận nhưng ở mức yếu cho thấy tuổi tác, giới tính và độ dốc đoạn ST cũng phần nào ảnh hưởng đến khả năng mắc bệnh tim nhưng xét về mức độ thì không mạnh bằng các biến phía trên.

Biến thalach là biến duy nhất có tương quan nghịch với biến target và có mức độ tương quan ở mức trung bình. cho thấy rằng nếu nhịp tim đạt được trong quá trình vận động tăng thì khả năng mắc bệnh tim có xu hướng giảm xuống và ngược lại.

##	Var1	Var2	Correlation	Group
## 1	age	thalach	-0.395	Yếu
## 2	oldpeak	thalach	-0.348	Yếu
## 3	age	trestbps	0.290	Yếu
## 4	age	chol	0.203	Yếu
## 5	age	oldpeak	0.197	Rất yếu
## 6	oldpeak	trestbps	0.191	Rất yếu
## 7	chol	trestbps	0.132	Rất yếu
## 8	thalach	trestbps	-0.049	Rất yếu
## 9	chol	oldpeak	0.039	Rất yếu
## 10	chol	thalach	0.000	Rất yếu

Các biến định lượng trong tập dữ liệu có mức tương quan thấp. Không xuất hiện mối tương quan mạnh giữa các biến độc lập, do đó có thể sử dụng đồng thời các biến trong quá trình mô hình phân tích và dự đoán mà không ảnh hưởng đến độ ổn định của mô hình

Mặc dù kết quả phân tích tương quan cho thấy các biến chỉ có mức tương quan từ yếu đến trung bình, việc đánh giá đa cộng tuyến vẫn cần được thực hiện để đảm bảo các biến độc lập không có mối liên hệ quá chặt chẽ với nhau. Vì vậy, nghiên cứu tiến hành kiểm tra đa cộng tuyến thông qua ma trận tương quan Pearson và hệ số VIF.


Đa cộng tuyến là hiện tượng các biến độc lập có mối tương quan cao với nhau, làm ảnh hưởng đến độ ổn định và khả năng giải thích của mô hình dự đoán. Để đánh giá hiện tượng này, nghiên cứu sử dụng ma trận tương quan Pearson kết hợp với hệ số phóng đại phương sai.

```
model_vif <- lm(
  target ~ .,
  data = data
)

vif(model_vif)
```

```
##      age      sex      cp trestbps      chol      fbs restecg thalach
## 1.492916 1.287653 1.321430 1.206235 1.138724 1.077901 1.091847 1.644291
##      exang oldpeak      slope      ca      thal
## 1.379085 1.762312 1.674866 1.348591 1.476910
```


Kết quả kiểm tra hệ số VIF cho thấy các giá trị VIF đều nhỏ hơn 5, dao động từ 1,078 đến 1,762. Điều này chứng tỏ hiện tượng đa cộng tuyến không xuất hiện trong bộ dữ liệu và các biến độc lập có thể được sử dụng đồng thời trong mô hình.



Từ kết quả của phần kiểm tra đa cộng tuyến và biểu đồ Heatmap tổng quan cho thấy có một số giá trị thuận nổi bật như oldpeak và slope, thal và target, target và oldpeak,... Nhìn chung dù không có cặp biến nào có hệ số tương quan tuyệt đối lớn hơn 0.8 nhưng Heatmap vẫn cho thấy dữ liệu có cấu trúc tương quan tương đối hợp lý, với đa số các biến chỉ có mức tương quan yếu đến trung bình, cho thấy các biến tương đối độc lập với nhau và cho thấy hiện tượng đa cộng tuyến nghiêm trọng không xuất hiện trong bộ dữ liệu và các biến có thể được sử dụng đồng thời trong các phân tích tiếp theo.

4.3. So sánh đặc điểm giữa nhóm mắc bệnh và không mắc bệnh

So sánh các biến định lượng giữa nhóm mắc bệnh (1) và không mắc bệnh (0)




Các biểu đồ cho thấy nhóm người mắc bệnh tim có xu hướng lớn tuổi hơn, chỉ số oldpeak cao hơn và nồng độ cholesterol cũng cao hơn so với nhóm người không mắc bệnh. Ngược lại, nhịp tim tối đa (thalach) của nhóm người mắc bệnh tim cao hơn so với nhóm người không mắc bệnh. Đối với huyết áp lúc nghỉ (trestbps) thì sự khác biệt giữa nhóm mắc bệnh và không mắc bệnh lại không quá rõ ràng.

Ngoài ra, một số giá trị ngoại lệ được ghi nhận ở các biến Cholesterol, Trestbps và Oldpeak, phản ánh sự tồn tại của một số bệnh nhân có đặc điểm lâm sàng khác biệt so với phần lớn các mẫu nghiên cứu

Qua những kết quả này phần nào chứng minh được mối tương quan giữa các biến như tuổi (age), nhịp tim tối đa (thalach) và chỉ số oldpeak có thể sẽ là những yếu tố liên quan đến tình trạng mắc bệnh tim và có thể đóng vai trò là những yếu tố quan trọng trong các phân tích và mô hình dự đoán.

So sánh các biến định tính giữa nhóm mắc bệnh (1) và không mắc bệnh (0)



Các biểu đồ cho thấy sự khác biệt tương đối rõ ràng giữa nhóm mắc bệnh tim và nhóm không mắc bệnh tim ở một số biến định tính. Đối với biến giới tính (sex), số lượng nam giới mắc bệnh tim cao hơn đáng kể so với nữ giới. Ở biến loại đau ngực (cp), sự phân bố giữa hai nhóm có sự khác biệt rõ rệt, trong đó một số loại đau ngực số 3 xuất hiện với tần suất cao hơn ở nhóm mắc bệnh tim. Tương tự, biến đau thắt ngực do gắng sức (Exang) cho thấy phần lớn bệnh nhân không mắc bệnh tim không xuất hiện triệu chứng đau thắt ngực khi gắng sức, trong khi tỷ lệ xuất hiện triệu chứng này ở nhóm mắc bệnh tim cao hơn đáng kể.

Đối với kết quả xét nghiệm Thalassemia (Thal), nhóm mắc bệnh tim tập trung chủ yếu ở giá trị phân loại 1 và 2 khá vượt trội. Bên cạnh đó, biến độ dốc đoạn ST khi gắng sức (Slope) nhóm không mắc bệnh tim tập trung chủ yếu ở một số mức 0 (bình thường), trong khi nhóm mắc bệnh tim có xu hướng phân bố nhiều hơn ở các mức độ 1 và 2.

Nhìn chung, các biến định tính được khảo sát đều thể hiện sự khác biệt về phân bố giữa nhóm mắc bệnh và không mắc bệnh tim, các biến đều cho thấy được sự phân tách tương đối rõ giữa hai nhóm. Qua đó cho thấy các đặc điểm lâm sàng và cận lâm sàng của bệnh nhân có mối liên hệ nhất định với tình trạng mắc bệnh tim. Đặc biệt, các biến như loại đau ngực (cp), đau thắt ngực do gắng sức (exang), kết quả Thalassemia (thal) và độ dốc đoạn ST khi gắng sức (slope) thể hiện khả năng phân biệt giữa hai nhóm tương đối tốt và có tiềm năng trở thành những yếu tố quan trọng trong việc giải thích và dự đoán nguy cơ mắc bệnh.

CHƯƠNG 5. XÂY DỰNG MÔ HÌNH HÓA DỮ LIỆU (DATA MODELING)

Sau khi hoàn tất quá trình khám phá và trực quan hóa để hiểu rõ các đặc trưng của tập dữ liệu, bước tiếp theo là chuyển sang giai đoạn xây dựng và đánh giá các mô hình học máy (Machine Learning). Giai đoạn này đóng vai trò quyết định trong việc chuyển đổi dữ liệu thô thành công cụ dự đoán hữu ích, giúp hỗ trợ y bác sĩ trong việc sàng lọc và phát hiện sớm nguy cơ mắc bệnh tim ở bệnh nhân.

5.1. Giới thiệu mô hình

Dựa trên mục tiêu của dự án và đặc điểm của bộ dữ liệu bệnh tim, ba mô hình học máy được lựa chọn để xây dựng và đánh giá khả năng dự đoán nguy cơ mắc bệnh tim

Hồi quy Logistic (Logistic Regression) là thuật toán thuộc nhóm học có giám sát với mục tiêu phân loại, được sử dụng để dự đoán khả năng một bệnh nhân mắc bệnh tim dựa trên các đặc trưng y tế quan trọng như tuổi, giới tính, huyết áp, mức cholesterol và nhịp tim tối đa.

K-Nearest Neighbors (KNN) là thuật toán học có giám sát thuộc nhóm phân loại, hoạt động dựa trên nguyên lý tìm kiếm sự tương đồng giữa các đối tượng. Để dự đoán tình trạng bệnh tim của một bệnh nhân, mô hình sẽ xác định và phân tích các trường hợp tương tự nhất đã có trong tập dữ liệu dựa trên khoảng cách giữa các đặc trưng y tế trong không gian dữ liệu, từ đó đưa ra kết luận dự báo cho bệnh nhân mới.

SVM là một thuật toán học có giám sát, được sử dụng để phân loại và hồi quy. Mục tiêu chính của SVM là tìm ra một siêu phẳng (hyperplane) sao cho có thể phân tách tối ưu các điểm dữ liệu thuộc hai lớp khác nhau. Siêu phẳng này được chọn sao cho khoảng cách giữa nó và các điểm dữ liệu gần nhất của mỗi lớp là lớn nhất.

Việc áp dụng đồng thời ba mô hình này cho phép đánh giá và so sánh hiệu quả của các phương pháp học máy khác nhau trong bài toán dự đoán bệnh tim. Thông qua các chỉ số đánh giá như Accuracy, Precision, Sensitivity, F1-score và Confusion Matrix, nghiên cứu có thể xác định mô hình phù hợp nhất, góp phần hỗ trợ phát hiện sớm và giảm thiểu nguy cơ mắc bệnh tim.

5.2. Chia tập dữ liệu

```
set.seed(123)
idx <- createDataPartition(data$target, p = 0.7, list = FALSE)
train <- data[idx, ]
test <- data[-idx, ]
```

Việc phân chia tập dữ liệu thành 70% huấn luyện (training) và 30% kiểm tra (testing) là cần thiết để đánh giá khả năng tổng quát hóa của mô hình trên dữ liệu mới thay vì chỉ học thuộc lòng dữ liệu cũ. Với một tập dữ liệu nhỏ (300 dòng), tỷ lệ 7:3 là một sự cân bằng hợp lý: nó cung cấp đủ dữ liệu (khoảng 210 dòng) để mô hình học được các quy luật, đồng thời giữ lại một lượng đủ (90 dòng) để kiểm chứng độ chính xác một cách khách quan. Nếu dùng toàn bộ dữ liệu để huấn luyện, bạn sẽ không thể biết được mô hình có bị quá khớp (overfitting) hay không, dẫn đến việc dự đoán sai trên thực tế.

5.3. Thiết lập Cross-Validation

```
ctrl_rep <- trainControl(
  method = "repeatedcv", number = 10, repeats = 5,
  classProbs = TRUE, summaryFunction = twoClassSummary,
  savePredictions = "final"
)

ctrl_svm <- trainControl(
  method = "repeatedcv",
  number = 10,
  repeats = 3,
  classProbs = TRUE,
  summaryFunction = twoClassSummary,
  savePredictions = "final"
)
```

Đối với Logistic Regression và KNN (ctrl_rep): Nhóm sử dụng phương pháp repeatedcv với number = 10 (10-fold) và repeats = 5. Việc lặp lại quy trình kiểm chứng chéo 5 lần giúp giảm thiểu phương sai trong ước lượng lỗi, tạo ra kết quả đánh giá ổn định hơn - một yếu tố then chốt khi làm việc với dữ liệu y tế có kích thước nhỏ và độ nhiễu cao.

Đối với SVM (ctrl_svm): Nhóm áp dụng repeatedcv với number = 10 và repeats = 3. Việc tinh chỉnh số lần lặp (repeats) thấp hơn so với các mô hình trước giúp cân bằng giữa tính ổn định của mô hình và thời gian huấn luyện, tránh việc quá phụ thuộc vào một cách phân chia dữ liệu cụ thể, vốn có thể ảnh hưởng đến biên phân tách (hyperplane) của SVM.

5.4. Xây dựng mô hình 1: Logistic Regression

5.4.1 Mục tiêu và phương pháp

Mục tiêu

Mô hình Logistic Regression được xây dựng nhằm mục tiêu dự đoán xác suất một bệnh nhân có mắc bệnh tim hay không dựa trên các chỉ số y tế. Đồng thời, mô hình còn giúp đánh giá mức độ ảnh hưởng của từng yếu tố nguy cơ đến bệnh tim, từ đó hỗ trợ các bác sĩ trong việc chẩn đoán và đưa ra phác đồ điều trị phù hợp.

Phương pháp

Chuẩn hóa dữ liệu (Preprocessing): Áp dụng center và scale để đưa các biến y tế về cùng thang đo chuẩn, giúp thuật toán hội tụ nhanh và các hệ số hồi quy phản ánh đúng tầm quan trọng của từng đặc trưng.

Điều chuẩn (Regularization) với glmnet: Sử dụng kết hợp Lasso ($\alpha=1$) để loại bỏ các nhiễu/biến không quan trọng và Ridge ($\alpha=0$) để xử lý đa cộng tuyến. Phương pháp này giúp mô hình tinh gọn và ổn định hơn.

Tối ưu hóa siêu tham số: Kết hợp *Grid Search* (trên dải giá trị α và λ) với *Repeated Cross-Validation* (10-fold, 5 repeats). Phương pháp này giúp tìm ra cấu hình tối ưu nhất trong không gian tham số, đồng thời giảm thiểu phương sai và rủi ro overfitting nhờ việc kiểm chứng chéo lặp lại nhiều lần.

5.4.2. Triển khai

Quá trình triển khai mô hình Logistic Regression trong R bao gồm các bước chính:

Huấn luyện mô hình train()

target ~ .: Dự báo biến mục tiêu dựa trên toàn bộ các biến đầu vào.

method = "glmnet": Sử dụng thuật toán Logistic với kỹ thuật điều chuẩn Elastic Net (kết hợp Ridge và Lasso).

trControl = ctrl_rep: Áp dụng Repeated Cross-Validation để đảm bảo tính ổn định và tránh quá khớp.

metric = "ROC": Tối ưu hóa mô hình dựa trên đường cong ROC, tiêu chuẩn vàng cho phân loại y tế.

`preProcess = c("center", "scale")`: Chuẩn hóa dữ liệu về cùng thang đo, giúp các trọng số hệ số hồi quy chính xác và công bằng.


`tuneGrid`: Thiết lập lưới tìm kiếm các siêu tham số α (cân bằng Ridge/Lasso) và λ (cường độ phạt) để tìm ra cấu hình mô hình tối ưu nhất.

Dự đoán và đánh giá mô hình

`predict(log_model, test)`: Sử dụng mô hình đã huấn luyện để dự đoán nhãn phân loại (Yes/No) cho tập test.

`predict(..., type = "prob")[, "Yes"]`: Dự đoán xác suất xảy ra của lớp "Yes". Kết quả này được dùng để tính toán các chỉ số chuyên sâu như AUC.

`confusionMatrix(...)`: Tạo ma trận nhầm lẫn để so sánh kết quả dự đoán với thực tế, từ đó tính toán Accuracy, Sensitivity, và Specificity.



5.5. Xây dựng mô hình 2: K - Nearest Neighbors (KNN)

5.5.1. Mục tiêu và Phương pháp

Mục tiêu

Phân loại dựa trên sự tương đồng của dữ liệu (instance-based learning). Thay vì xây dựng một hàm toán học tổng quát như Logistic Regression, KNN dự đoán tình trạng bệnh của một bệnh nhân bằng cách nhìn vào các bệnh nhân có đặc điểm y tế tương tự nhất trong tập huấn luyện.

Phương pháp

Chuẩn hóa dữ liệu (Preprocessing): Vì KNN dựa trên khoảng cách (thường là khoảng cách Euclidean) giữa các điểm dữ liệu, các biến có thang đo lớn hơn sẽ chi phối kết quả. Việc sử dụng `preProcess = c("center", "scale")` đảm bảo mọi biến y tế đều đóng góp công bằng vào việc tính toán khoảng cách.

Tham số `k` (Number of Neighbors): Nếu `k` quá nhỏ, mô hình dễ bị nhiễu (overfitting); nếu `k` quá lớn, mô hình trở nên quá khái quát (underfitting). Nhóm sẽ sử dụng `tuneGrid` để thử nghiệm dải giá trị `k` khác nhau nhằm tìm ra giá trị cân bằng nhất.

Kiểm chứng chéo (Cross-Validation): Sử dụng `ctrl_rep` (Repeated Cross-Validation, 10-fold, 5 repeats) để đảm bảo mô hình KNN ổn định. Do tính chất của KNN là tính toán trực tiếp trên dữ liệu, việc kiểm chứng chéo lặp lại giúp đánh giá chính xác khả năng khái quát của mô hình trên các nhóm bệnh nhân khác nhau.

Sử dụng `metric = "ROC"` và `twoClassSummary` tương tự như Logistic Regression để đảm bảo sự nhất quán trong việc đánh giá hiệu năng phân loại y khoa, đặc biệt là khả năng phân biệt giữa nhóm có bệnh và nhóm khỏe mạnh.

5.5.2. Triển khai

Quá trình triển khai KNN trong R được thực hiện thông qua gói `caret`:

Huấn luyện mô hình `train()`

`target ~ .`: Dự đoán mục tiêu dựa trên tất cả các biến đầu vào.

`method = "knn"`: Sử dụng thuật toán láng giềng gần nhất để phân loại.

`trControl = ctrl_rep`: Áp dụng *Repeated Cross-Validation* để đảm bảo tính ổn định của mô hình.

`metric = "ROC"`: Chọn mô hình dựa trên diện tích dưới đường cong ROC.

`preProcess = c("center", "scale")`: Chuẩn hóa dữ liệu về cùng thang đo, bước bắt buộc để KNN tính khoảng cách chính xác.

Tham số tối ưu


`knn_model$bestTune`: Trả về cấu hình tham số k đã mang lại giá trị ROC cao nhất trong quá trình huấn luyện.

Dự đoán và đánh giá

`knn_pred <- predict(knn_model, test)`: Sử dụng mô hình đã huấn luyện để dự đoán nhãn phân loại ("Yes" hoặc "No") cho tập dữ liệu kiểm thử (test).

`knn_prob <- predict(knn_model, test, type = "prob")[, "Yes"]`: Chọn cột xác suất tương ứng với lớp "Yes". Giá trị này dùng để đánh giá độ tự tin của mô hình và tính toán đường cong ROC.

`knn_cm <- confusionMatrix(knn_pred, test$target, positive = "Yes")`: Xác định lớp "Yes" là lớp dương tính để tính toán các chỉ số quan trọng trong y tế như Độ nhạy (Sensitivity) và Độ đặc hiệu (Specificity).



5.6. Xây dựng mô hình 3: Support Vector Machine (SVM)

5.6.1. Mục tiêu và phương pháp

Mục tiêu

Tìm kiếm một siêu phẳng (hyperplane) tối ưu trong không gian đa chiều để phân tách bệnh nhân thành hai nhóm (có bệnh/khỏe mạnh) với khoảng cách (margin) lớn nhất. Sử dụng nhân Radial Basis Function (RBF) giúp mô hình nắm bắt được các mối quan hệ phi tuyến tính phức tạp trong dữ liệu y tế, nơi ranh giới giữa bệnh và không bệnh thường không nằm trên một đường thẳng.

Phương pháp

Kernel RBF (svmRadial): Chuyển đổi dữ liệu sang không gian chiều cao hơn để tìm ranh giới phân tách mượt mà, giúp xử lý các trường hợp dữ liệu chồng lấp.

Tối ưu hóa siêu tham số (Grid Search): σ - Điều khiển tầm ảnh hưởng của các điểm dữ liệu (độ cong của ranh giới). C (Cost) - Kiểm soát sự đánh đổi giữa việc tối đa hóa khoảng cách biên và việc hạn chế các điểm dữ liệu bị phân loại sai (tránh quá khớp).

Tiền xử lý: Luôn thực hiện center và scale để đưa các biến y tế về cùng thang đo, giúp việc tính toán khoảng cách trong không gian kernel chính xác.

Kiểm chứng chéo (ctrl_svm): Sử dụng *Repeated Cross-Validation* (10-fold, 3 lặp) để đảm bảo mô hình ổn định, tránh kết quả phụ thuộc vào cách phân chia dữ liệu ngẫu nhiên.

5.6.2. Triển khai

Quá trình triển khai mô hình Support Vector Machine trong R bao gồm các bước chính:

Huấn luyện mô hình train()

target ~.: Dự báo biến mục tiêu (target) dựa trên tất cả các biến độc lập còn lại trong tập dữ liệu.

method: Chỉ định thuật toán sử dụng ("svmRadial" cho SVM).

trControl: Áp dụng quy trình kiểm chứng chéo (Repeated Cross-Validation) để đảm bảo độ ổn định và tránh quá khớp (overfitting).

metric = "ROC": Chọn diện tích dưới đường cong ROC làm tiêu chuẩn để đánh giá và chọn mô hình tốt nhất.

preProcess = c("center", "scale"): Chuẩn hóa dữ liệu (đưa về trung bình bằng 0, độ lệch chuẩn bằng 1).


tuneGrid: Thiết lập lưới siêu tham số cần tối ưu để tìm ra cấu hình mô hình hiệu quả nhất.

Dự đoán và đánh giá mô hình

predict(model, test): Sử dụng mô hình đã học để dự đoán nhãn phân loại rời rạc (ví dụ: "Yes" hoặc "No") cho từng bệnh nhân trong tập test.

predict(model, test, type = "prob")[, "Yes"]: Dự đoán xác suất xảy ra của lớp "Yes". Kết quả này là dữ liệu quan trọng để vẽ đường cong ROC và tính chỉ số AUC.

`confusionMatrix(..., positive = "Yes")`: So sánh nhãn dự đoán với thực tế để tạo ma trận nhầm lẫn, từ đó tính toán các chỉ số chuyên môn như Độ chính xác (Accuracy), Độ nhạy (Sensitivity) và Độ đặc hiệu (Specificity).



CHƯƠNG 6. THỰC NGHIỆM, KẾT QUẢ VÀ THẢO LUẬN

6.1. Kết quả Mô hình 1: Logistic Regression

Mô hình *Logistic Regression* được xây dựng để dự đoán nguy cơ mắc bệnh tim (biến *heart_disease*) dựa trên các chỉ số y tế đầu vào.

6.1.1. Đánh giá mô hình

Mô hình Logistic Regression được huấn luyện với thuật toán glmnet kết hợp Regularization (Ridge và Lasso) thông qua tham số alpha và lambda. Việc sử dụng kỹ thuật này giúp giảm overfitting và tự động lựa chọn đặc trưng quan trọng, đặc biệt hữu ích khi dữ liệu y tế có nhiều biến số tương quan với nhau. Quá trình tối ưu siêu tham số được thực hiện trên lưới tìm kiếm với $\alpha \in \{0, 0.25, 0.5, 0.75, 1\}$ và 20 giá trị lambda khác nhau, kết hợp với Repeated Cross-Validation (10 folds, 5 repeats) để đảm bảo đánh giá chính xác.

```
set.seed(123)
log_model <- train(
  target ~ ., data = train, method = "glmnet",
  trControl = ctrl_rep, metric = "ROC",
  preProcess = c("center", "scale"),
  tuneGrid = expand.grid(
    alpha = c(0, 0.25, 0.5, 0.75, 1),
    lambda = 10^seq(-4, 0, length = 20)
  )
)

log_pred <- predict(log_model, test)
log_prob <- predict(log_model, test, type = "prob")[, "Yes"]
log_cm <- confusionMatrix(log_pred, test$target, positive = "Yes")

cat("Logistic - CV AUC:", round(max(log_model$results$ROC), 4), "\n")
```

6.1.2 Kết quả đánh giá

```
## Logistic - CV AUC: 0.9108
```

Kết quả đạt được cho thấy mô hình có AUC trên CV là 0.9108, cho thấy khả năng phân biệt giữa bệnh nhân có và không có bệnh tim là rất tốt (trên 0.9).

```
print(log_cm)
```

```
## Confusion Matrix and Statistics
##
##           Reference
## Prediction No Yes
##           No  42   9
##           Yes   6  32
##
##           Accuracy : 0.8315
##           95% CI : (0.7373, 0.9025)
##           No Information Rate : 0.5393
##           P-Value [Acc > NIR] : 6.345e-09
##
##           Kappa : 0.659
##
##  Mcnemar's Test P-Value : 0.6056
##
##           Sensitivity : 0.7805
##           Specificity : 0.8750
##           Pos Pred Value : 0.8421
##           Neg Pred Value : 0.8235
##           Prevalence : 0.4607
##           Detection Rate : 0.3596
##           Detection Prevalence : 0.4270
##           Balanced Accuracy : 0.8277
##
##           'Positive' Class : Yes
##
```

Trên tập kiểm tra, mô hình đạt độ chính xác Accuracy = 83.15% (khoảng tin cậy 95%: 73.73% – 90.25%), với Sensitivity = 78.05% và Specificity = 87.50%. Điều này cho thấy mô hình có xu hướng dự đoán đúng người không có bệnh tốt hơn người có bệnh. Chỉ số Kappa = 0.659 cho thấy sự đồng thuận giữa dự đoán và thực tế ở mức khá. Giá trị P-Value (6.345e-09) nhỏ hơn 0.05 cho thấy độ chính xác của mô hình cao hơn đáng kể so với tỷ lệ ngẫu nhiên (No Information Rate = 53.93%). Mô hình Logistic Regression với Regularization đã cho thấy hiệu quả dự đoán tốt trong bài toán chẩn đoán bệnh tim.

6.1.3. Kết luận

Mô hình Logistic Regression đạt kết quả tốt, có khả năng phân biệt bệnh nhân mắc và không mắc bệnh tim ở mức rất tốt ($AUC > 0.9$), với độ đặc hiệu (87.50%) cao hơn độ nhạy (78.05%), cho thấy xu hướng phát hiện đúng người không bệnh tốt hơn. Kết quả này khẳng định mô hình Logistic Regression có thể ứng dụng hiệu quả trong hỗ trợ chẩn đoán bệnh tim, đồng thời Regularization giúp mô hình tổng quát hóa tốt và hạn chế overfitting trên dữ liệu y tế.

6.2. Kết quả Mô hình 2: K - Nearest Neighbors (KNN)

6.2.1. Đánh giá mô hình

```
set.seed(123)
knn_model <- train(
  target ~ ., data = train, method = "knn",
  trControl = ctrl_rep, metric = "ROC",
  preProcess = c("center", "scale"),
  tuneGrid = expand.grid(k = seq(5, 31, by = 2))
)

best_k <- knn_model$bestTune$k
knn_pred <- predict(knn_model, test)
knn_prob <- predict(knn_model, test, type = "prob")[, "Yes"]
knn_cm <- confusionMatrix(knn_pred, test$target, positive = "Yes")

cat("KNN - k tối ưu:", best_k, "| CV AUC:", round(max(knn_model$results$ROC), 4), "\n")
```

```
## KNN - k tối ưu: 27 | CV AUC: 0.8987
```

Mô hình KNN được huấn luyện với giá trị k được tối ưu trong khoảng từ 5 đến 31 (bước nhảy 2), sử dụng Repeated Cross-Validation (10 folds, 5 repeats) với chỉ số đánh giá ROC. Kết quả huấn luyện cho thấy giá trị k tối ưu là 27, đạt CV AUC = 0.8987. Đây là mức AUC khá tốt, cho thấy KNN có khả năng phân biệt giữa bệnh nhân có và không có bệnh tim ở mức chấp nhận được.

6.2.2. Đánh giá kết quả


```
print(knn_cm)
```

```
## Confusion Matrix and Statistics
##
##              Reference
## Prediction No Yes
##      No   45  12
##      Yes   3  29
##
##              Accuracy : 0.8315
##              95% CI : (0.7373, 0.9025)
##      No Information Rate : 0.5393
##      P-Value [Acc > NIR] : 6.345e-09
##
##              Kappa : 0.6553
##
##      Mcnemar's Test P-Value : 0.03887
##
##              Sensitivity : 0.7073
##              Specificity : 0.9375
##      Pos Pred Value : 0.9063
##      Neg Pred Value : 0.7895
##      Prevalence : 0.4607
##      Detection Rate : 0.3258
##      Detection Prevalence : 0.3596
##      Balanced Accuracy : 0.8224
##
##      'Positive' Class : Yes
##
```

Trên tập kiểm tra, KNN đạt Accuracy = 83.15% (khoảng tin cậy 95%: 73.73% – 90.25%), với Sensitivity = 70.73% và Specificity = 93.75%. So với các chỉ số này, KNN có độ đặc hiệu rất cao (93.75%), nghĩa là mô hình rất giỏi trong việc phát hiện đúng người không có bệnh (chỉ sai 3/48 trường hợp). Tuy nhiên, độ nhạy chỉ đạt 70.73%, thấp hơn Logistic (78.05%), cho thấy KNN có xu hướng bỏ sót nhiều bệnh nhân thực sự mắc bệnh hơn (12/41 ca dương tính bị dự đoán sai). Độ nhạy thấp là một hạn chế đáng kể trong bối cảnh y tế, vì việc bỏ sót bệnh nhân có nguy cơ (False Negative) có thể gây hậu quả nghiêm trọng.

6.2.3. Đánh giá biểu đồ trực quan

```
plot(knn_model)
```



Khi k tăng từ 5 lên khoảng 15, AUC tăng khá nhanh, cho thấy việc tăng số láng giềng giúp giảm nhiễu và cải thiện độ chính xác đáng kể.

Từ $k = 15$ đến $k = 27$, AUC tiếp tục tăng nhưng với tốc độ chậm hơn, đạt đỉnh tại $k = 27$.

Sau $k = 27$, AUC có xu hướng giảm nhẹ, phản ánh hiện tượng underfitting khi mô hình sử dụng quá nhiều láng giềng, làm mờ ranh giới phân tách giữa hai lớp.

Điểm đặc biệt là AUC dao động tương đối ổn định trong khoảng $k = 15$ đến $k = 31$, cho thấy KNN khá bền vững với sự thay đổi của k trong vùng này.

Giá trị $k = 27$ tối ưu – tương đối lớn so với kích thước tập huấn luyện (khoảng 207 mẫu), phù hợp với đặc điểm dữ liệu y tế có nhiều và cần nhiều láng giềng để đưa ra quyết định ổn định.

6.2.4. Kết luận

Mô hình KNN với $k = 27$ cho thấy hiệu quả dự đoán tốt với AUC 0.8987 và độ chính xác 83.15%. Mô hình có ưu điểm nổi bật về độ đặc hiệu (93.75%), rất phù hợp để xác định chính xác người không mắc bệnh, giảm thiểu chi phí xét nghiệm không cần thiết. Tuy nhiên, độ nhạy thấp (70.73%) là điểm yếu cần lưu ý, vì có thể bỏ sót bệnh nhân có nguy cơ. KNN là mô hình đơn giản, dễ hiểu và không yêu cầu giả định về phân phối dữ liệu, phù hợp làm mô hình tham khảo trong bài toán dự đoán bệnh tim.

6.3. Kết quả Mô hình 3: Support Vector Machine (SVM)

6.3.1. Đánh giá mô hình

Dựa trên kết quả từ các nghiên cứu trước đó, mô hình SVM với kernel Radial thường đạt hiệu suất cao trong các bài toán phân loại y tế nhờ khả năng xử lý các mối quan hệ phi tuyến phức tạp giữa các chỉ số lâm sàng. Lưới siêu tham số với $\sigma \in \{0.001, 0.01, 0.05, 0.1\}$ và $C \in \{0.01, 0.1, 0.5, 1, 2\}$ được thiết lập để tìm kiếm cấu hình tối ưu, giúp mô hình đạt được độ chính xác và khả năng tổng quát hóa tốt nhất.

```
set.seed(123)

svm_grid <- expand.grid(
  sigma = c(0.001, 0.01, 0.05, 0.1),
  C      = c(0.01, 0.1, 0.5, 1, 2)
)

svm_model <- train(
  target ~ ., data = train,
  method    = "svmRadial",
  trControl = ctrl_svm,
  metric     = "ROC",
  preProcess = c("center", "scale"),
  tuneGrid   = svm_grid
)

cat("=== SVM - Tham số tối ưu ===\n")

# Dự đoán trên test
svm_pred <- predict(svm_model, test)
svm_prob <- predict(svm_model, test, type = "prob")[, "Yes"]
svm_cm   <- confusionMatrix(svm_pred, test$target, positive = "Yes")
print(svm_cm)
```

Việc sử dụng Cross-Validation (ctrl_svm) kết hợp với chỉ số ROC đảm bảo quá trình đánh giá khách quan và hạn chế overfitting. Mô hình SVM dự kiến sẽ cho kết quả khả quan với các chỉ số như Accuracy, Sensitivity và AUC, từ đó có thể so sánh với Logistic Regression để chọn ra mô hình phù hợp nhất cho bài toán chẩn đoán bệnh tim.

6.3.2. Kết quả

```
## === SVM - Tham số tối ưu ===
```

```
print(svm_model$bestTune)
```

```
##      sigma C  
## 5 0.001 2
```

```
cat("CV AUC (best):", round(max(svm_model$results$ROC), 4), "\n")
```

```
## CV AUC (best): 0.9185
```

Kết quả cho thấy bộ tham số tối ưu là $\sigma = 0.001$ và $C = 2$, đạt CV AUC = 0.9185 – cao nhất trong ba mô hình được thử nghiệm (Logistic: 0.9108, KNN: 0.8987). Điều này cho thấy SVM có khả năng phân biệt giữa bệnh nhân có và không có bệnh tim tốt nhất trên tập validation.

```
## Confusion Matrix and Statistics  
##  
##           Reference  
## Prediction No Yes  
##           No  40   9  
##           Yes   8  32  
##  
##           Accuracy : 0.809  
##           95% CI : (0.7119, 0.8846)  
##           No Information Rate : 0.5393  
##           P-Value [Acc > NIR] : 9.657e-08  
##  
##           Kappa : 0.6149  
##  
##           McNemar's Test P-Value : 1  
##  
##           Sensitivity : 0.7805  
##           Specificity : 0.8333  
##           Pos Pred Value : 0.8000  
##           Neg Pred Value : 0.8163  
##           Prevalence : 0.4607  
##           Detection Rate : 0.3596  
##           Detection Prevalence : 0.4494  
##           Balanced Accuracy : 0.8069  
##  
##           'Positive' Class : Yes  
##
```


Trên tập kiểm tra, SVM đạt Accuracy = 80.90% (khoảng tin cậy 95%: 71.19% – 88.46%), với Sensitivity = 78.05% và Specificity = 83.33%. So với Logistic Regression

(Accuracy 83.15%), SVM có độ chính xác thấp hơn khoảng 2.25%. Điều này cho thấy mặc dù SVM có CV AUC tốt hơn, nhưng hiệu suất trên tập kiểm tra lại không vượt trội so với Logistic Regression. Nguyên nhân có thể do SVM dễ bị overfitting hơn khi dữ liệu có kích thước nhỏ (chỉ 297 mẫu), hoặc do lưới siêu tham số chưa được tối ưu đủ rộng để tìm ra cấu hình tốt nhất cho tập test.

6.3.3. Biểu đồ trực quan

Biểu đồ CV AUC theo sigma và C:

```
# Visualize
plot(svm_model, main = "SVM - CV AUC theo sigma và C")
```



Giá trị sigma nhỏ (0.001) cho hiệu suất tốt nhất, phù hợp với dữ liệu y tế có khoảng cách giữa các điểm dữ liệu tương đối lớn – kernel rộng giúp mô hình tổng quát hóa tốt hơn.

Giá trị $C = 2$ cho hiệu suất cao nhất, cho thấy mô hình cần dung sai lỗi thấp (hard margin) để phân tách chính xác các lớp bệnh/không bệnh.

Khi sigma tăng dần (0.01 $\rightarrow$ 0.1), AUC có xu hướng giảm, đặc biệt với C nhỏ, cho thấy kernel hẹp khiến mô hình quá nhạy cảm với nhiễu và không tổng quát hóa tốt.

Điểm đáng chú ý là AUC đạt đỉnh tại sigma = 0.001, $C = 2$, sau đó giảm dần, khẳng định sự cân bằng quan trọng giữa hai siêu tham số này.

6.3.4. Kết luận

Mô hình SVM cho thấy tiềm năng tốt với CV AUC cao (0.9185), nhưng hiệu suất trên tập kiểm tra thực tế thấp hơn Logistic Regression. Với dữ liệu y tế có kích thước nhỏ, SVM dễ bị overfitting và yêu cầu tinh chỉnh siêu tham số cẩn thận. Do đó, Logistic Regression vẫn là lựa chọn cân bằng hơn về độ chính xác và khả năng tổng quát hóa.

6.4. So sánh các mô hình

```
get_metrics <- function(cm, name) {
  data.frame(Model      = name,
             Accuracy   = cm$overall["Accuracy"],
             Sensitivity = cm$byClass["Sensitivity"],
             Precision   = cm$byClass["Precision"],
             F1         = cm$byClass["F1"])
}

results <- rbind(
  get_metrics(log_cm, "Logistic (Elastic Net)"),
  get_metrics(knn_cm, paste0("KNN (k=", best_k, ")")),
  get_metrics(svm_cm, "SVM")
)
print(results)
```


	Model	Accuracy	Sensitivity	Precision	F1
## Accuracy	Logistic (Elastic Net)	0.8314607	0.7804878	0.8421053	0.8101266
## Accuracy1	KNN (k=27)	0.8314607	0.7073171	0.9062500	0.7945205
## Accuracy2	SVM	0.8089888	0.7804878	0.8000000	0.7901235

Dựa trên các chỉ số Accuracy, Sensitivity, Precision và F1-score, có thể nhận thấy:

Mô hình Logistic Regression (Elastic Net) đạt Accuracy cao nhất (83.15%) và F1-score cao nhất (81.01%), cho thấy khả năng dự đoán tổng thể cân bằng và ổn định nhất trong ba mô hình.

KNN ($k = 27$) đạt Precision cao nhất (90.63%), nghĩa là khi mô hình dự đoán bệnh nhân mắc bệnh tim thì độ chính xác rất cao. Tuy nhiên, Sensitivity thấp nhất (70.73%), cho thấy mô hình bỏ sót khá nhiều trường hợp mắc bệnh.

SVM có các chỉ số tương đối cân bằng nhưng đều thấp hơn Logistic Regression, với Accuracy 80.90% và F1-score 79.01%.




Từ biểu đồ và bảng kết quả, có thể thấy Logistic Regression (Elastic Net) là mô hình có hiệu năng tốt nhất vì vừa đạt độ chính xác cao, vừa duy trì sự cân bằng giữa khả năng phát hiện bệnh nhân mắc bệnh (Sensitivity) và độ tin cậy của dự đoán (Precision).

Mô hình Logistic Regression (Elastic Net) được lựa chọn làm mô hình cuối cùng cho bài toán dự đoán bệnh tim do đạt Accuracy = 83.15%, Sensitivity = 78.05%, Precision = 84.21% và F1-score = 81.01%, cao hoặc cân bằng hơn so với các mô hình còn lại. Điều này cho thấy mô hình có khả năng tổng quát hóa tốt và phù hợp để sử dụng trong bước dự đoán bệnh nhân mới.

6.5. Biểu đồ ROC-AUC

Đường cong ROC (Receiver Operating Characteristic) được sử dụng để đánh giá khả năng phân biệt giữa hai lớp của các mô hình phân loại. Chỉ số AUC (Area Under the Curve) càng gần 1 thì mô hình càng có khả năng phân loại tốt.



Biểu đồ ROC cho thấy cả ba mô hình đều có đường cong nằm khá xa đường chéo ngẫu nhiên, chứng tỏ chúng có khả năng phân biệt tốt giữa bệnh nhân mắc bệnh tim và không mắc bệnh tim.

Logistic Regression (Elastic Net) đạt $AUC = 0.919$, cao nhất trong ba mô hình. Điều này cho thấy mô hình có khả năng phân loại rất tốt, với xác suất khoảng 91.9% phân biệt đúng giữa hai lớp. SVM đạt $AUC = 0.905$, thấp hơn Logistic Regression nhưng vẫn thuộc mức rất tốt ($AUC > 0.9$). KNN ($k = 27$) đạt $AUC = 0.904$, gần tương đương với SVM nhưng thấp hơn một chút.

Khoảng cách AUC giữa các mô hình không quá lớn (chênh lệch khoảng 0.01–0.02), cho thấy cả ba mô hình đều hoạt động hiệu quả trên tập dữ liệu. Tuy nhiên, Logistic Regression (Elastic Net) vẫn thể hiện ưu thế rõ rệt khi đạt AUC cao nhất, đồng thời cũng có Accuracy và F1-score cao nhất trong phần đánh giá trước đó.

Kết quả này củng cố quyết định lựa chọn Logistic Regression (Elastic Net) làm mô hình cuối cùng cho bài toán dự đoán bệnh tim.

6.6. Kiểm tra Overfitting

Để đánh giá khả năng tổng quát hóa của các mô hình, nghiên cứu tiên hành so sánh độ chính xác trên tập huấn luyện (Train Accuracy) và tập kiểm tra (Test Accuracy).

Chênh lệch giữa hai giá trị này được biểu diễn bằng chỉ số Gap, trong đó Gap càng nhỏ thì mô hình càng ổn định và ít có nguy cơ xảy ra hiện tượng overfitting.

```
get_acc <- function(model, data, target) {  
  cm <- confusionMatrix(predict(model, data), target)  
  cm$overall["Accuracy"]  
}  
  
comparison <- data.frame(  
  Model = c("Logistic (Elastic Net)", paste0("KNN (k=", best_k, ")"), "SVM"),  
  Train_Acc = c(get_acc(log_model, train, train$target),  
                get_acc(knn_model, train, train$target),  
                get_acc(svm_model, train, train$target)),  
  Test_Acc = c(get_acc(log_model, test, test$target),  
               get_acc(knn_model, test, test$target),  
               get_acc(svm_model, test, test$target))  
)  
comparison$Gap <- comparison$Train_Acc - comparison$Test_Acc  
print(comparison)
```

```
##           Model Train_Acc Test_Acc      Gap  
## 1 Logistic (Elastic Net) 0.8461538 0.8314607 0.0146931720  
## 2           KNN (k=27) 0.8317308 0.8314607 0.0002700951  
## 3           SVM 0.8413462 0.8089888 0.0323573898
```

Kết quả cho thấy mô hình Logistic Regression (Elastic Net) đạt Train Accuracy = 84.62% và Test Accuracy = 83.15%, với Gap = 0.0147. Mô hình KNN (k = 27) đạt Train Accuracy = 83.17% và Test Accuracy = 83.15%, với Gap chỉ bằng 0.0003. Trong khi đó, mô hình SVM đạt Train Accuracy = 84.13% và Test Accuracy = 80.90%, tương ứng Gap = 0.0324.

```
for (i in 1:nrow(comparison)) {  
  cat(sprintf("%-25s - Gap = %.4f %s\n",  
              comparison$Model[i], comparison$Gap[i],  
              ifelse(comparison$Gap[i] > 0.05, "Có dấu hiệu overfit", "Ổn định")))  
}
```

```
## Logistic (Elastic Net) - Gap = 0.0147 Ổn định  
## KNN (k=27)           - Gap = 0.0003 Ổn định  
## SVM                  - Gap = 0.0324 Ổn định
```

Cả ba mô hình đều có giá trị Gap nhỏ hơn 0.05, cho thấy không xuất hiện hiện tượng overfitting đáng kể. Đặc biệt, KNN (k = 27) có khoảng cách giữa tập huấn luyện và tập kiểm tra nhỏ nhất, thể hiện tính ổn định cao nhất. Logistic Regression (Elastic Net) cũng duy trì sự ổn định tốt với mức chênh lệch thấp. Mặc dù SVM có Gap lớn hơn hai mô

hình còn lại, giá trị này vẫn nằm trong ngưỡng chấp nhận được và không cho thấy dấu hiệu quá khớp dữ liệu.


6.7. Ma trận nhầm lẫn (Confusion Matrix)

Ma trận nhầm lẫn (Confusion Matrix) là công cụ trực quan quan trọng để đánh giá hiệu suất phân loại của từng mô hình.

```
plot_cm <- function(cm, title) {  
  as.data.frame(cm$table) |>  
  ggplot(aes(Prediction, Reference, fill = Freq)) +  
  geom_tile() +  
  geom_text(aes(label = Freq), color = "white", size = 6) +  
  scale_fill_gradient(low = "lightblue", high = "darkblue") +  
  labs(title = title) + theme_minimal()  
}  
  
plot_cm(log_cm, "Confusion Matrix - Logistic Regression (Elastic Net)")
```

Biểu đồ heatmap dưới đây thể hiện số lượng dự đoán đúng và sai của ba mô hình Logistic Regression, KNN và SVM trên tập kiểm tra.


6.7.1. Logistic Regression



Ma trận nhầm lẫn của Logistic Regression cho thấy mô hình dự đoán đúng 42 trường hợp không bệnh và 32 trường hợp có bệnh. Sai sót gồm 9 ca bệnh bị bỏ sót (False


Negative) và 6 ca khỏe mạnh bị cảnh báo sai (False Positive). Tỷ lệ sai lệch giữa hai loại lỗi tương đối cân bằng, cho thấy mô hình hoạt động ổn định và không thiên lệch về một phía nào. Điều này phù hợp với chỉ số Sensitivity (78.05%) và Specificity (87.50%) ở mức tốt và cân đối.

6.7.2. K – Nearest Neighbors (KNN)



KNN đạt 45 dự đoán đúng không bệnh và 29 dự đoán đúng có bệnh. Điểm nổi bật là False Positive chỉ 3 – thấp nhất trong ba mô hình, giúp KNN có Specificity cao nhất (93.75%), nghĩa là rất ít khi cảnh báo sai cho người khỏe mạnh. Tuy nhiên, False Negative lên tới 12 – cao nhất trong ba mô hình, cho thấy KNN bỏ sót nhiều ca bệnh thực tế nhất (Sensitivity chỉ 70.73%). Đây là hạn chế đáng kể trong bối cảnh y tế, vì bỏ sót bệnh nhân có nguy cơ có thể gây hậu quả nghiêm trọng.

6.7.3. Support Vector Machine (SVM)



SVM dự đoán đúng 40 trường hợp không bệnh và 32 trường hợp có bệnh. Số False Positive là 8 và False Negative là 9, cho thấy sự cân bằng tương đối giữa hai loại sai sót. Tuy nhiên, tổng số dự đoán sai lên tới 17 – cao nhất trong ba mô hình, dẫn đến Accuracy thấp nhất (80.90%). Mặc dù SVM có CV AUC cao nhất (0.9185), ma trận nhầm lẫn cho thấy hiệu suất thực tế trên tập kiểm tra chưa thực sự vượt trội.

6.7.4. Kết luận

Qua ba heatmap, ta có thể thấy rõ đặc trưng của từng mô hình:


- *KNN* giỏi nhận diện người không bệnh nhất (45 đúng, ít FP nhất) nhưng bỏ sót nhiều ca bệnh nhất (12 FN).
- *Logistic Regression* có sự phân bố lỗi cân bằng nhất, là mô hình ổn định nhất.
- *SVM* có tổng sai sót cao nhất (17), dù CV AUC tốt nhất.

Trong bối cảnh y tế, việc bỏ sót bệnh (False Negative) nghiêm trọng hơn cảnh báo sai (False Positive). Logistic Regression với 9 FN và 6 FP thể hiện sự cân bằng tối ưu giữa hai loại sai sót, là lựa chọn đáng tin cậy nhất cho bài toán chẩn đoán bệnh tim.

6.8. Đánh giá mức độ ảnh hưởng của các biến lâm sàng

6.8.1. Đánh giá các biến

Để đánh giá một cách khách quan và chính xác nhất, ta sử dụng bảng đánh giá của mô hình Logistic Regression. Mô hình cung cấp khả năng đánh giá mức độ ảnh hưởng của từng biến số đến nguy cơ mắc bệnh tim thông qua hệ số hồi quy sau khi áp dụng Regularization. Biểu đồ dưới đây thể hiện 10 biến có tầm ảnh hưởng mạnh nhất đến dự đoán bệnh tim.



Kết quả phân tích cho thấy một số biến có mức độ ảnh hưởng đáng kể đến khả năng dự đoán bệnh tim của mô hình:

Thal2 – Bất thường tưới máu cơ tim dạng cố định

Biến thal2 có mức độ ảnh hưởng cao nhất trong mô hình. Trong lâm sàng, tình trạng bất thường tưới máu cơ tim dạng cố định (Fixed Defect) thường phản ánh vùng cơ tim đã bị tổn thương vĩnh viễn do các biến cố tim mạch trước đó, chẳng hạn như nhồi máu cơ tim. Do đó, sự xuất hiện của đặc trưng này làm tăng đáng kể xác suất dự đoán mắc bệnh tim.

Cp3 – Đau ngực không do tim

Biến cp3 được xếp ở vị trí quan trọng thứ hai. Mặc dù đây là loại đau ngực thường được xem là ít liên quan trực tiếp đến bệnh tim, kết quả cho thấy trong bộ dữ liệu nghiên cứu, đặc trưng này vẫn có giá trị dự báo đáng kể. Điều này cho thấy nguy cơ bệnh tim không chỉ xuất hiện ở những bệnh nhân có triệu chứng điển hình mà còn có thể xuất hiện ở các trường hợp biểu hiện không đặc trưng.

Ca1 và Ca0 – Số lượng mạch máu lớn bị ảnh hưởng

Các biến liên quan đến số lượng mạch máu lớn bị ảnh hưởng (ca) xuất hiện nhiều trong nhóm đặc trưng quan trọng. Điều này cho thấy mức độ tổn thương hoặc tắc nghẽn mạch vành có mối liên hệ chặt chẽ với nguy cơ mắc bệnh tim. Đặc biệt, ngay cả trường hợp chỉ có một mạch máu bị ảnh hưởng (ca1) cũng đã tạo ra tác động đáng kể đến kết quả dự đoán.

Oldpeak – Độ chênh ST khi gắng sức

Oldpeak là một trong những biến số liên tục quan trọng nhất của mô hình. Chỉ số này phản ánh mức độ suy giảm đoạn ST trên điện tâm đồ khi gắng sức. Giá trị oldpeak càng cao thường cho thấy tình trạng thiếu máu cơ tim càng nghiêm trọng, từ đó làm gia tăng nguy cơ mắc bệnh tim.

Thalach – Nhịp tim tối đa đạt được

Biến thalach phản ánh khả năng đáp ứng của tim trong quá trình vận động hoặc gắng sức. Giá trị thalach thấp thường liên quan đến khả năng hoạt động kém của hệ tim mạch và có thể là dấu hiệu của các bệnh lý mạch vành tiềm ẩn.

Ngoài các biến trên, mô hình còn ghi nhận mức độ ảnh hưởng đáng kể từ các đặc trưng như:

sex1 (Nam giới): Nam giới có xu hướng có nguy cơ mắc bệnh tim mạch cao hơn so với nữ giới.

slope2 (Đoạn ST phẳng): Là dấu hiệu bất thường thường gặp trong các trường hợp thiếu máu cơ tim.

exang1 (Đau thắt ngực khi gắng sức): Phản ánh tình trạng tim không được cung cấp đủ máu khi hoạt động mạnh.

cp2 (Đau ngực không điển hình): Cho thấy các triệu chứng không điển hình vẫn mang giá trị dự báo nhất định đối với bệnh tim.

6.8.2. Nhận định về các yếu tố

Về mặt y tế, kết quả cho thấy các dấu hiệu tổn thương tim mạch và bất thường ở mạch vành là những yếu tố quan trọng nhất trong việc đánh giá nguy cơ mắc bệnh tim. Các chỉ số thu được từ nghiệm pháp gắng sức như *oldpeak*, *thalach*, *slope* và *exang* có giá trị dự báo cao, khẳng định vai trò của các xét nghiệm gắng sức trong hỗ trợ sàng lọc và chẩn đoán bệnh tim.

Sự xuất hiện của các biến liên quan đến đau ngực không điển hình cho thấy nguy cơ bệnh tim không chỉ biểu hiện qua các triệu chứng kinh điển. Do đó, trong thực hành y khoa, cần đánh giá toàn diện các triệu chứng kết hợp với kết quả xét nghiệm thay vì chỉ dựa trên biểu hiện lâm sàng ban đầu.

Nhìn chung, mô hình cho thấy việc kết hợp các thông tin về tổn thương tim mạch, chức năng tim khi gắng sức và đặc điểm triệu chứng có thể hỗ trợ hiệu quả cho quá trình sàng lọc, đánh giá nguy cơ và phát hiện sớm bệnh tim mạch.

6.9. Dự đoán bệnh nhân mắc bệnh tim

Phần này minh họa quy trình dự đoán cho một bệnh nhân mới dựa trên các mô hình đã huấn luyện, nhằm đánh giá khả năng ứng dụng thực tế của hệ thống trong hỗ trợ chẩn đoán bệnh tim.

6.9.1. Thông tin bệnh nhân

Nghiên cứu khảo sát một bệnh nhân nam, 35 tuổi, có tình trạng sức khỏe tim mạch với các thông số ghi nhận gồm: huyết áp tâm thu 120 mmHg, nồng độ cholesterol 198 mg/dl và đường huyết lúc đói ở ngưỡng bình thường. Bệnh nhân có biểu hiện đau ngực kiểu không do tim và ghi nhận tình trạng đau thắt ngực khi gắng sức. Các chỉ số chức năng tim mạch cho thấy nhịp tim tối đa đạt 130 bpm, chỉ số ST depression ghi nhận ở mức 1.6 với dạng đoạn ST dốc xuống. Điện tâm đồ nghỉ ở trạng thái bình thường, không có mạch máu chính bị ảnh hưởng và tình trạng thalassemia được ghi nhận ở mức 2. Đây là bệnh nhân có nhiều yếu tố nguy cơ của bệnh tim mạch.

```
# Bệnh nhân mới (giá trị thực tế)
new_patient <- data.frame(
  age = z(35, "age"),
  sex = factor(1, levels = levels(train$sex)),
  cp = factor(3, levels = levels(train$cp)),
  trestbps = z(120, "trestbps"),
  chol = z(198, "chol"),
  fbs = factor(0, levels = levels(train$fbs)),
  restecg = factor(0, levels = levels(train$restecg)),
  thalach = z(130, "thalach"),
  exang = factor(1, levels = levels(train$exang)),
  oldpeak = z(1.6, "oldpeak"),
  slope = factor(2, levels = levels(train$slope)),
  ca = factor(as.character(z(0, "ca")), levels = levels(train$ca)),
  thal = factor(2, levels = levels(train$thal))
)
```

6.9.2. Quá trình triển khai

Dữ liệu bệnh nhân mới được tiền xử lý giống như dữ liệu huấn luyện: các biến số định lượng được chuẩn hóa (center, scale) dựa trên giá trị trung bình và độ lệch chuẩn của tập huấn luyện, các biến phân loại được chuyển đổi sang factor tương ứng. Sau đó, ba mô hình đã huấn luyện (Logistic Regression, KNN và SVM) lần lượt được sử dụng để dự đoán xác suất mắc bệnh của bệnh nhân này.

```
heart_raw <- read.csv(file.path("C:\\TaiLieuHocTap\\R\\HD\\Dataset\\heart_disease_dataset_clean.csv"), stringsAsFactors = FALSE)

# Hàm chuẩn hóa Z-score
z <- function(x, col) {
  (x - mean(heart_raw[[col]])) / sd(heart_raw[[col]])
}

# Dự đoán
p_log <- predict(log_model, new_patient, type = "prob")[, "Yes"]
p_knn <- predict(knn_model, new_patient, type = "prob")[, "Yes"]
p_svm <- predict(svm_model, new_patient, type = "prob")[, "Yes"]

p_result <- p_log # dùng kết quả của logistic regression để dự đoán
# p_result <- mean(c(p_log, p_knn, p_svm)) # dùng trung bình dự đoán từ 3 mô hình để dự đoán
```


6.9.3. Kết quả dự đoán

```
## === KẾT QUẢ DỰ ĐOÁN ===
```

```
cat(sprintf(" Logistic: %.4f | KNN: %.4f | SVM: %.4f | Voting: %.4f\n", p_log, p_knn, p_svm, p_result))
```

```
## Logistic: 0.7373 | KNN: 0.6296 | SVM: 0.8833 | Voting: 0.7373
```

```
cat(ifelse(
  p_result > 0.5,
  "\nCẢNH BÁO: BỆNH NHÂN CÓ NGUY CƠ BỆNH TIM",
  "\nBÌNH THƯỜNG: BỆNH NHÂN KHÔNG CÓ NGUY CƠ BỆNH TIM"
))
```

```
##
## CẢNH BÁO: BỆNH NHÂN CÓ NGUY CƠ BỆNH TIM
```

Kết quả dự đoán xác suất mắc bệnh tim mạch từ ba mô hình cho thấy sự đồng thuận cao: Logistic Regression (73.73%), KNN (62.96%) và SVM (88.33%). Sự khác biệt về giá trị xác suất giữa các mô hình phản ánh cách tiếp cận toán học khác nhau: SVM thể hiện sự thận trọng và nhạy bén hơn với dữ liệu có tính phi tuyến, trong khi Logistic Regression và KNN cung cấp cái nhìn tổng quan dựa trên xác suất tuyến tính và phân bố lân cận. Với kết quả dự đoán cuối cùng (Voting) đạt 73.73%, vượt ngưỡng an toàn 50%, hệ thống đưa ra cảnh báo: “*Bệnh nhân có nguy cơ mắc bệnh tim*”.

Dựa trên kết quả dự đoán của mô hình Logistic Regression (73.73%), bệnh nhân 35 tuổi này được xác định có nguy cơ mắc bệnh tim mạch dù còn trẻ. Kết quả này phản ánh chính xác các yếu tố nguy cơ tiềm ẩn như đau thắt ngực khi gắng sức, chỉ số ST depression bất thường và tình trạng thalassemia mức 2. Điều này khẳng định tiềm năng của các mô hình học máy trong việc hỗ trợ bác sĩ sàng lọc sớm và đưa ra quyết định lâm sàng chính xác hơn.

CHƯƠNG 7. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

7.1. Kết luận

Đề tài "Dự đoán nguy cơ mắc bệnh tim dựa trên dữ liệu y tế bằng các mô hình Machine Learning" đã hoàn thành các mục tiêu đề ra ban đầu. Nhóm đã tiến hành nghiên cứu bộ dữ liệu bệnh tim, thực hiện các bước khám phá dữ liệu và tiền xử lý dữ liệu nhằm đảm bảo chất lượng dữ liệu trước khi xây dựng mô hình. Dữ liệu đã được làm sạch và chuẩn hóa trước khi đưa vào xây dựng mô hình nhằm đảm bảo chất lượng và độ tin cậy của kết quả.

Trên cơ sở dữ liệu đã được xử lý, nhóm đã xây dựng và đánh giá các mô hình Machine Learning gồm Logistic Regression (Elastic Net), K-Nearest Neighbors (KNN) và Support Vector Machine (SVM). Kết quả thực nghiệm cho thấy các mô hình đều có khả năng dự đoán nguy cơ mắc bệnh tim với độ chính xác tương đối tốt. Trong đó, mô hình Logistic Regression (Elastic Net) cho kết quả cân bằng nhất với Accuracy 0.831, Sensitivity 0.780, Precision 0.842 và F1-score 0.810, cho thấy khả năng dự đoán ổn định giữa các tiêu chí đánh giá.

Kết quả nghiên cứu cho thấy Machine Learning có tiềm năng hỗ trợ hiệu quả trong việc dự đoán và phát hiện sớm nguy cơ mắc bệnh tim, góp phần hỗ trợ quá trình sàng lọc và chăm sóc sức khỏe trong thực tế.

7.2. Hạn chế của nghiên cứu

Mặc dù đã đạt được những kết quả nhất định, đề tài vẫn còn một số hạn chế cần được xem xét và khắc phục trong các nghiên cứu tiếp theo. Các mô hình được sử dụng trong nghiên cứu gồm Logistic Regression (Elastic Net), K-Nearest Neighbors (KNN) và Support Vector Machine (SVM) đều là các mô hình Machine Learning phổ biến. Tuy nhiên, khả năng khai thác các mối quan hệ phức tạp trong dữ liệu vẫn còn hạn chế so với một số mô hình học máy nâng cao hoặc học sâu hiện đại.

Bộ dữ liệu sử dụng trong nghiên cứu được thu thập từ một nguồn dữ liệu có sẵn và chưa phản ánh đầy đủ đặc điểm của nhiều nhóm đối tượng khác nhau. Điều này có thể ảnh hưởng đến khả năng tổng quát hóa của mô hình khi áp dụng vào thực tế.

Trong phạm vi đề án, nhóm mới chỉ thử nghiệm ba thuật toán gồm Logistic Regression (Elastic Net), KNN và SVM. Các mô hình nâng cao hơn như XGBoost, Gradient Boosting hoặc Neural Network chưa được nghiên cứu và đánh giá. Ngoài ra, các kỹ thuật tối ưu mô hình chuyên sâu như tối ưu siêu tham số nâng cao hoặc lựa chọn đặc trưng chuyên sâu vẫn chưa được khai thác nhiều.

Do thời gian thực hiện có hạn và kinh nghiệm thực tế còn hạn chế, nhóm mới chỉ dừng lại ở việc xây dựng và đánh giá mô hình trên tập dữ liệu nghiên cứu mà chưa triển khai thành một hệ thống hỗ trợ chẩn đoán hoàn chỉnh trong thực tế. Những hạn chế trên cũng là cơ sở để nhóm tiếp tục hoàn thiện và phát triển đề tài trong tương lai, hướng tới việc nâng cao hiệu suất và khả năng ứng dụng của mô hình trong thực tế.

7.3. Hướng phát triển trong tương lai

Từ những kết quả đạt được cũng như các hạn chế còn tồn tại, đề tài vẫn còn nhiều tiềm năng để tiếp tục nghiên cứu và hoàn thiện trong tương lai nhằm nâng cao hiệu suất dự đoán và khả năng ứng dụng trong thực tế.

Trước hết, cần mở rộng quy mô và tính đa dạng của bộ dữ liệu bằng cách thu thập thêm dữ liệu từ nhiều nguồn khác nhau, đồng thời bổ sung các đặc trưng y khoa và thông tin liên quan đến lối sống của bệnh nhân. Bên cạnh đó, các kỹ thuật xử lý dữ liệu nâng cao như cân bằng dữ liệu, lựa chọn đặc trưng và tối ưu siêu tham số có thể được áp dụng nhằm cải thiện chất lượng dữ liệu và hiệu quả của mô hình.

Ngoài việc tiếp tục tối ưu các mô hình hiện tại như Logistic Regression (Elastic Net), KNN và SVM, đề tài có thể được mở rộng bằng cách thử nghiệm thêm các thuật toán Machine Learning nâng cao như XGBoost, Gradient Boosting hoặc các mô hình Deep Learning nhằm tìm ra phương pháp phù hợp hơn cho bài toán dự đoán nguy cơ mắc bệnh tim.

Cuối cùng, mô hình có thể được triển khai thành một hệ thống hoặc ứng dụng hỗ trợ dự đoán nguy cơ mắc bệnh tim, giúp người dùng hoặc nhân viên y tế nhanh chóng đánh giá mức độ rủi ro dựa trên các chỉ số sức khỏe đầu vào. Những hướng phát triển này sẽ góp phần nâng cao độ chính xác, tính ổn định và khả năng ứng dụng của mô hình trong thực tế.

BẢNG PHÂN CÔNG VÀ ĐÁNH GIÁ

MÔN HỌC: LẬP TRÌNH R CHO PHÂN TÍCH

GVHD: TS. Phan Thị Thê

Github: <https://github.com/dwnngnn/Heart-Disease>

NHÓM 14

Họ và tên	MSSV	Nhiệm vụ	Mức độ hoàn thành	Điểm đánh giá của nhóm Thái độ, mức độ hoàn thành	Điểm đánh giá của GV
Dương Thị Kim Ngân	24133040	- Tổng hợp nội dung, tài liệu tham khảo và viết báo cáo. - Lý thuyết bệnh tim, Machine Learning. - Xây dựng và huấn luyện các mô hình Machine Learning. - Quản lý mã nguồn Github.	100%	10	
Nguyễn Minh Thư	24133061	- Trực quan hóa dữ liệu. - Lý thuyết bài toán nhị phân.	100%	10	

Nguyễn Thị Kiều Trang	24133064	- Tiền xử lí, chuẩn hóa dữ liệu. - Kết luận tổng quát, đưa ra hướng phát triển.	100%	10	
Nguyễn Thị Ngọc Trâm	24133066	- Tóm tắt, chương giới thiệu. - Lý thuyết Machine Learning. - Khám phá dữ liệu. - Xây dựng và huấn luyện các mô hình Machine Learning.	100%	10	

Đánh giá chung về quá trình làm việc nhóm: Nhóm đã có sự phối hợp tốt trong suốt quá trình thực hiện đồ án. Các buổi họp nhóm diễn ra đều đặn và hiệu quả trong việc trao đổi ý tưởng, giải quyết vấn đề và phân chia công việc. Nhìn chung, các thành viên đều nỗ lực hoàn thành phần việc được giao.

TÀI LIỆU THAM KHẢO

- [1] A. Araveeporn and P. Wanitjirattikal, “Comparison of Machine Learning Methods for Binary Classification of Multicollinearity Data,” in *Proceedings of the 2024 7th International Conference on Mathematics and Statistics*, in ICoMS '24. New York, NY, USA: Association for Computing Machinery, Dec. 2024, pp. 44–49. doi: 10.1145/3686592.3686600.
- [2] W. Qian, J. Huang, F. Xu, W. Shu, and W. Ding, “A survey on multi-label feature selection from perspectives of label fusion,” *Inf. Fusion*, vol. 100, p. 101948, Dec. 2023, doi: 10.1016/j.inffus.2023.101948.
- [3] P. Yang and J. Yu, “Challenges in Binary Classification,” Jun. 19, 2024, *arXiv*: arXiv:2406.13665. doi: 10.48550/arXiv.2406.13665.
- [4] “Chi tiết khoá học Machine Learning và ứng dụng,” VIMENTOR. Accessed: Jun. 14, 2026. [Online]. Available: <https://vimentor.com/vi/course/machine-learning-for-data-science-and-analytics/>
- [5] Ultralytics, “Data Preprocessing là gì? Hướng dẫn cho ML & YOLO26,” Ultralytics. Accessed: Jun. 14, 2026. [Online]. Available: <https://www.ultralytics.com/vi/glossary/data-preprocessing>
- [6] “Các kỹ thuật tiền xử lý dữ liệu cho dữ liệu Computer Vision đã được chú thích,” Tài liệu Ultralytics. Accessed: Jun. 14, 2026. [Online]. Available: https://docs.ultralytics.com/vi/guides/preprocessing_annotated_data
- [7] T. M. Mitchell, *Machine Learning*. in McGraw-Hill series in computer science. New York: McGraw-Hill, 1997.
- [8] Khôi L. H., “Machine Learning là gì? Vai trò, Ứng dụng chính của công nghệ Máy học,” Base Blog. Accessed: Jun. 14, 2026. [Online]. Available: <https://base.vn/blog/machine-learning-la-gi/>
- [9] “Học máy (Machine Learning) là gì? Cách hoạt động và ứng dụng.” Accessed: Jun. 14, 2026. [Online]. Available: <https://fpt-is.com/goc-nhin-so/hoc-may-la-gi/>
- [10] D. Bergmann, “What is Machine Learning? | IBM.” Accessed: Jun. 14, 2026. [Online]. Available: <https://www.ibm.com/think/topics/machine-learning>

- [11] “Giới thiệu về Support Vector Machine (SVM).” Accessed: Jun. 18, 2026. [Online]. Available: <https://viblo.asia/p/gioi-thieu-ve-support-vector-machine-svm-6J3ZgPVEImB>
- [12] “Tất tần tật về thuật toán K-Nearest Neighbors (KNN) trong Học máy - VinBigdata.” Accessed: Jun. 14, 2026. [Online]. Available: <https://vinbigdata.com/kham-pha/tat-tan-tat-ve-thuat-toan-k-nearest-neighbors-knn-trong-hoc-may.html>
- [13] “Hồi quy Logistic (Logistic Regression) — Tài liệu ML Glossary.” Accessed: Jun. 14, 2026. [Online]. Available: https://ml-glossary-vn.readthedocs.io/vi/latest/logistic_regression_vn.html