

BOOTSTRAP

1. Bootstrap là gì?

Bootstrap là một phương pháp thống kê dựa trên việc lấy mẫu lại (resampling) từ dữ liệu hiện có, nhằm ước lượng độ không chắc chắn (uncertainty) của một thống kê nào đó (ví dụ: trung bình, trung vị, độ lệch chuẩn, v.v.).

Mục đích chính:

- Tạo **phân phối gần đúng** của một thống kê (sampling distribution) mà **không cần giả định phân phối chuẩn**.
- Từ đó ta có thể:
 - Tính **khoảng tin cậy** (confidence interval).
 - Thực hiện **kiểm định giả thuyết**.
 - Ước lượng **độ lệch chuẩn** (standard error).

2. Gói bootstrap trong R

R có **nhiều cách để thực hiện bootstrap**, và các gói phổ biến bao gồm:

Gói	Mục tiêu chính
boot	Gói cơ bản để thực hiện bootstrap với các hàm tùy chỉnh
infer	Rất thuận tiện cho kiểm định giả thuyết và trực quan hóa
rsample, tidymodels	Thường dùng trong học máy (machine learning)

Trong tài liệu của bạn, **gói infer** là gói được sử dụng để thực hiện bootstrap.

3. Cách bootstrap hoạt động

Ví dụ minh họa từng bước (R dùng infer):

```
library(infer)
library(dplyr)

# Giả sử bạn có dữ liệu về chiều cao của 100 người
set.seed(42)

height_data <- tibble(height = rnorm(100, mean = 170, sd = 5))
```

Bước 1: Tính trung bình thực tế

```
obs_mean <- height_data %>%  
  specify(response = height) %>%  
  calculate(stat = "mean")
```

Bước 2: Tạo 1000 mẫu bootstrap (lấy mẫu lại có hoàn lại)

```
boot_dist <- height_data %>%  
  specify(response = height) %>%  
  generate(reps = 1000, type = "bootstrap") %>%  
  calculate(stat = "mean")
```

Bước 3: Tính khoảng tin cậy 95%

```
ci <- boot_dist %>%  
  get_confidence_interval(  
    point_estimate = obs_mean,  
    level = 0.95,  
    type = "percentile" # hoặc "se"  
  )
```

Bước 4: Trực quan hóa phân phối bootstrap

```
boot_dist %>%  
  visualize() +  
  shade_confidence_interval(endpoints = ci)
```

In kết quả

```
print(obs_mean)  
print(ci)
```

Lưu ý khi dùng bootstrap

- Dữ liệu gốc phải **đại diện tốt cho quần thể**.

- Không nên dùng bootstrap khi **cỡ mẫu quá nhỏ** (ví dụ dưới 20 quan sát).
- Đối với thống kê lệch mạnh (skewed), nên dùng **percentile interval** thay vì `type = "se"`.